

一、数据挖掘导论 (Introduction to Data Mining)

- 第一部分：核心概念与定义
 - 为什么要进行数据挖掘? (Motivation)
 - 什么是数据挖掘? (KDD vs DM)
 - 数据库技术的演变
- 第二部分：KDD 过程 (知识发现过程)
 - 7大步骤详解 (清洗、集成、选择、变换、挖掘、评估、呈现)
- 第三部分：功能与任务
 - 描述性 vs 预测性
 - 概念描述、关联分析、分类、聚类、异常值、趋势分析
- 第四部分：系统架构 (Architecture)
 - 典型组件与 OLAM 架构
- 第五部分：应用领域
 - 市场、金融、医疗、零售等
- 第六部分：主要问题与挑战
- 第七部分：公式详解与例题预测
 - 关联规则计算 (Support & Confidence)
 - 聚类原则与模式兴趣度
- 第八部分：简答题与论述题预测

二、数据预处理 (Data Preprocessing)

- 第一部分：概述
 - 数据质量维度与 GIGO 原则
- 第二部分：主要任务
 - 清洗、集成、转换、缩减、离散化
- 第三部分：详细技术与考点 (核心计算区)
 - 数据清理：缺失值处理、分箱平滑 (Binning) 计算
 - 数据集成：编辑距离 (Edit Distance) 计算
 - 数据转换：规范化 (Min-Max, Z-score, Decimal Scaling)
 - 数据缩减：决策树信息增益 (Information Gain) 计算
 - 离散化：3-4-5 规则应用
- 第四部分：考试题型预测

三、数据仓库与 OLAP 技术

- 第一部分：核心概念
 - 数据仓库定义与四大特征 (面向主题、集成、时变、非易失)
 - 重点对比：OLTP vs OLAP
- 第二部分：多维数据模型

- 数据立方体 (Data Cube) 与 格结构
 - 三种模式: 星型、雪花、事实星座
 - 度量分类: 分布式、代数式、整体式
- 第三部分: OLAP 操作与实现
 - 上卷、下钻、切片、切块、旋转
 - ROLAP vs MOLAP vs HOLAP
- 第四部分: 关键公式与计算
 - 长方体数量计算公式
 - 位图索引与连接索引
- 第五部分: 高级话题
 - 发现驱动探索、OLAM、元数据
- 第六部分: 必考题目预测与标准答案

四、分类和预测 (Classification & Prediction)

- 模块一: 基础概念
 - 分类 (离散) vs 预测 (连续)
 - 监督学习 vs 无监督学习
- 模块二: 决策树归纳
 - 算法: ID3 (信息增益), C4.5, CART (基尼系数)
 - 重点计算: 熵 (Entropy) 与 信息增益 (Gain)
 - 剪枝策略 (过拟合处理)
- 模块三: 贝叶斯分类
 - 贝叶斯定理与朴素贝叶斯 (Naive Bayes) 计算
 - 贝叶斯信念网络
- 模块四: 神经网络
 - MLP 与 反向传播 (权重更新公式)
- 模块五: 其他分类方法
 - k-NN (懒惰学习)、CBR、遗传算法、模糊集
- 模块六: 预测/回归
- 模块七: 评估与提升
 - 交叉验证、Bootstrap、Bagging vs Boosting
- 综合考题预测

五、聚类分析 (Clustering Analysis)

- 第一部分: 基础
 - 聚类目标与要求
 - 数据结构 (数据矩阵 vs 相异度矩阵)
- 第二部分: 数据类型与距离度量 (计算核心)
 - 区间标度 (闵可夫斯基、欧几里得、曼哈顿)
 - 二元变量 (Jaccard 系数)

- 名义、序数与混合类型
- 第三部分：主要聚类方法
 - 划分方法：K-Means vs K-Medoids (PAM)
 - 层次方法：AGNES, DIANA, BIRCH, CURE
 - 基于密度：DBSCAN (核心点、密度可达)
 - 基于网格与基于模型
- 第四部分：异常值发现
- 第五部分：公式详解与例题
 - Jaccard 计算、CF 向量加法、DBSCAN 判定
- 第六部分：对比与策略预测

六、异常值分析 (Outlier Analysis)

- 第一部分：基础概念
 - 异常值 vs 噪声
 - 三种类型：全局、上下文、集体
- 第二部分：检测方法分类
 - 监督、无监督、半监督
- 第三部分：统计方法 (重点公式)
 - 参数方法：Z-score, 格鲁布斯检验
 - 多变量：马哈拉诺比斯距离, 卡方统计
- 第四部分：邻近度方法
 - 基于距离 (嵌套循环, 网格剪枝)
 - 基于密度 (LOF思想)
- 第五部分：聚类与分类方法
- 第六部分：高维数据异常检测
 - 维数灾难
 - HilOut, 网格子空间, ABOF (基于角度)
- 第七部分：考题预测 (场景设计与计算)

七、基础频繁模式与关联规则

- 第一部分：基本概念
 - 支持度 (Support) & 置信度 (Confidence)
 - 闭项集 vs 最大项集
- 第二部分：Apriori 算法
 - 先验性质 (剪枝原理)
 - 连接与剪枝步骤
- 第三部分：FP-Growth 算法
 - FP-Tree 构建与条件模式基
- 第四部分：垂直数据格式 (ECLAT)
- 第五部分：模式评估 (必考)

- 提升度 (Lift) 计算与判断
 - 卡方检验与零无关度量
- 第六部分：公式详解与例题
 - Apriori 剪枝推演、Lift 计算
- 第七部分：简答题预测

八、高级频繁模式挖掘

- 第一部分：多层与多维挖掘
 - 统一支持度 vs 递减支持度
 - 多维关联规则与属性处理
- 第二部分：稀有与负相关模式
 - 负相关判定 (Kulczynski 度量 vs 支持度定义)
- 第三部分：基于约束的挖掘 (难点)
 - 约束类型：反单调、单调、简洁、可转换
 - 利用约束进行剪枝
- 第四部分：庞大模式挖掘
 - Colossal Patterns 与 Pattern-Fusion 算法
- 第五部分：压缩与近似模式
- 第六部分：公式与考题预测
 - 约束性质判断题
 - 负相关模式计算题

一：数据挖掘导论

第一部分：核心概念与定义 (Basic Concepts)

1. 为什么要进行数据挖掘？(Motivation)

1. 背景：

1. **数据爆炸**：自动化数据收集工具和成熟的数据库技术导致海量数据积累（数据库、数据仓库）。
2. **矛盾**：我们被数据淹没，却又渴望知识 (Data rich, but information poor)。
3. **需求**：需要从数据中提取有价值的信息，“需要是发明之母”。

2. 解决方案：数据仓库 (Data Warehouse) 和数据挖掘 (Data Mining)。

2. 什么是数据挖掘？(Definition)

- **标准定义**：从大型数据库中提取**有趣的**（非平凡的、隐含的、先前未知的、潜在有用的）信息或模式的过程。
- **别名**：

1. 数据库中的知识发现 (KDD - Knowledge Discovery in Databases) —— 注: KDD是更广泛的过程, 数据挖掘是其中的核心步骤。
 2. 知识提取 (Knowledge Extraction)
 3. 数据/模式分析 (Data/Pattern Analysis)
 4. 数据考古 (Data Archeology)
 5. 商业智能 (Business Intelligence)
- 非数据挖掘范畴:
 - (演绎) 查询处理 (传统的数据库查询, 如“查找所有叫张三的人”)。
 - 专家系统。
 - 小型统计程序。

3. 数据库技术的演变 (Evolution)

1. **1960s**: 数据收集、数据库创建、IMS、网络DBMS。
2. **1970s**: 关系数据模型、关系DBMS实现。
3. **1980s**: RDBMS普及、高级数据模型 (扩展关系、面向对象、演绎)、面向应用的DBMS (空间、科学)。
4. **1990s-2000s**: 数据挖掘、数据仓库、多媒体数据库、Web数据库。

第二部分: KDD 过程 (知识发现过程) —— 考点高发区

数据挖掘是KDD过程的核心。一个完整的KDD过程包含以下步骤 (按顺序):

1. **数据清理 (Data Cleaning)**: 去除噪声和不一致的数据。 (PPT提到: 可能占用60%的工作量)
2. **数据集成 (Data Integration)**: 多种数据源组合在一起。
3. **数据选择 (Data Selection)**: 从数据库中检索与分析任务相关的数据。
4. **数据变换 (Data Transformation)**: 数据缩减、汇总, 将数据转换为适合挖掘的形式 (如归一化)。
5. **数据挖掘 (Data Mining)**: **核心步骤**。使用智能方法提取数据模式。
6. **模式评估 (Pattern Evaluation)**: 根据某种兴趣度度量, 识别代表知识的真正有趣的模式。
7. **知识呈现 (Knowledge Presentation)**: 使用可视化和知识表示技术向用户展示挖掘出的知识。

第三部分: 数据挖掘的功能与任务 (Functionalities)

数据挖掘主要用来发现两类知识: **描述性 (Descriptive)** 和 **预测性 (Predictive)**。

1. 概念描述 (Concept Description)

1. **特征化 (Characterization)**: 概括和总结目标类数据的特征 (例如: 总结“高消费客户”的

共同特征)。

2. **区分 (Discrimination)**: 将目标类数据与对比类数据进行比较 (例如: 比较“干旱地区”与“湿润地区”的特征)。

2. 关联分析 (Association) —— 计算题考点

1. **定义**: 发现数据项之间频繁出现的关联或相关性。
2. **例子**: 啤酒与尿布。
3. **关键指标**:
 - **支持度 (Support)**: 规则在所有事务中出现的概率。
 - **置信度 (Confidence)**: 在包含A的事务中, 同时包含B的条件概率。

3. 分类与预测 (Classification & Prediction)

1. **分类**: 找出一个模型 (函数) 来描述和区分数据类别, 用于预测未知对象的类标签 (离散值)。
 1. **方法**: 决策树、神经网络、分类规则。
 2. **例子**: 根据油耗将汽车分类; 检测信用卡交易是否为欺诈。
2. **预测**: 预测某些未知或缺失的数值 (连续值)。

4. 聚类分析 (Clustering)

1. **定义**: 在没有类别标签 (无监督学习) 的情况下, 将数据对象分组。
2. **原则**: 最大化类内相似度 (Intra-class similarity), 最小化类间相似度 (Inter-class similarity)。
3. **用途**: 寻找数据的自然分布模式。

5. 异常值分析 (Outlier Analysis)

1. **定义**: 分析不符合数据一般行为的对象。
2. **应用**: 欺诈检测、罕见事件分析 (虽然常被视为噪声, 但在这些领域非常有价值)。

6. 趋势与演变分析 (Trend & Evolution)

1. 涉及时间序列数据, 分析随时间变化的趋势、周期性等。

第四部分：数据挖掘系统架构 (Architecture)

典型的数据挖掘系统包含以下组件 (从底层到顶层)：

1. **数据库/数据仓库服务器**: 负责提取相关数据。
2. **知识库 (Knowledge Base)**: 提供领域知识, 指导搜索或评估模式。
3. **数据挖掘引擎 (Data Mining Engine)**: **核心部分**, 包含各种算法 (分类、聚类、关联等)。
4. **模式评估模块 (Pattern Evaluation)**: 与挖掘引擎交互, 过滤不感兴趣的模式 (使用阈值

等)。

5. **图形用户界面 (GUI)**: 用户与系统交互的接口, 负责可视化。

OLAM (Online Analytical Mining) 架构:

1. 结合了OLAP (联机分析处理) 和数据挖掘, 允许在多维数据库 (数据立方体) 上进行挖掘。

第五部分: 应用领域 (Applications)

PPT中列举了详细的应用场景, 考试可能考简答题或案例分析:

- **市场分析与管理:**
 1. **目标营销**: 寻找具有相同特征 (兴趣、收入) 的客户群。
 2. **市场篮子分析**: 交叉销售 (买了A通常会买B)。
 3. **客户流失分析**: 预测哪些客户会离开。
- **企业分析与风险管理:**
 1. 财务规划、资产评估。
 2. 竞争对手监控。
- **欺诈检测:**
 - **医疗保健**: 发现不必要的筛查测试。
 - **零售**: 员工盗窃。
 - **电信**: 电话卡欺诈 (如分析通话时长、目的地模式)。
 - **反洗钱**。
- **其他:**
 - **体育**: IBM Advanced Scout 分析NBA数据 (帮助尼克斯队和热火队)。
 - **天文学**: JPL发现类星体。
 - **Web分析**: IBM Surf-Aid 分析网页浏览行为。

第六部分: 主要问题与挑战 (Major Issues)

- **挖掘方法**: 不同类型的知识挖掘、多层抽象挖掘、交互式挖掘、背景知识整合。
- **性能**: 效率、可扩展性 (算法能否处理海量数据)、并行/分布式挖掘。
- **数据多样性**: 处理复杂数据类型 (文本、多媒体、空间数据)、异构数据库。
- **社会影响**: 隐私保护、数据安全。

第七部分: 公式详解与例题预测 (Formulas & Prediction)

虽然PPT中没有列出复杂的数学推导, 但**关联规则 (Association Rules)** 的定义给了具体的数值例子, 这是最可能出计算题的地方。

1. 关联规则计算 (Association Rules)

PPT原文引用：

$\text{Age}(X, "20..29") \wedge \text{Income}(X, "20..29K") \rightarrow \text{Buys}(X, "PC")$

[Support = 2%, Confidence = 60%]

公式详解：

假设我们有一组交易数据 T ，规则为 $A \Rightarrow B$ （如果发生A，则发生B）。

- 支持度 (Support):

表示 A 和 B 同时发生的概率。

$$\text{Support}(A \Rightarrow B) = P(A \cup B) = \frac{\text{包含A和B的事务数}}{\text{总事务数}}$$

解释：PPT中的 2% 意味着在所有被分析的记录中，有 2% 的人既在20-29岁且收入20-29K，又买了PC。

- 置信度 (Confidence):

表示在 A 发生的条件下， B 发生的条件概率。

$$\text{Confidence}(A \Rightarrow B) = P(B|A) = \frac{\text{包含A和B的事务数}}{\text{包含A的事务数}}$$

解释：PPT中的 60% 意味着在所有“20-29岁且收入20-29K”的人群中，有 60% 的人购买了PC。

预测考题 (计算类):

题目：某超市有10条交易记录。其中购买牛奶的有6条，购买面包的有7条，同时购买牛奶和面包的有4条。

请计算规则“买牛奶 $\Rightarrow$ 买面包”的支持度和置信度。

解答：

- 总事务数 $N = 10$ 。

- $A = \text{买牛奶}, B = \text{买面包}$ 。
- $\text{Count}(A) = 6, \text{Count}(A \cup B) = 4$ 。
- 支持度 = $4/10 = 40\%$ 。
- 置信度 = $4/6 \approx 66.7\%$ 。

2. 聚类原则 (Clustering Principle)

知识点：最大化类内相似度，最小化类间相似度。

预测考题 (判断/填空)：

题目：在聚类分析中，优秀的聚类结果应该满足什么条件？

答案：同一个簇内的对象越相似越好（类内相似度高），不同簇的对象越不同越好（类间相似度低）。

3. 模式兴趣度 (Pattern Interestingness)

知识点：什么样的模式是有趣的？

1. 易于被人理解。
2. 在拥有一定程度的确定性 (Confidence高)。
3. 潜在有用。
4. 新颖。

客观度量：支持度、置信度。

主观度量：是否符合用户预期（意外性）。

第八部分：可能的简答题与论述题预测

Q1: 请简述KDD（数据库知识发现）的步骤。

1. 参考答案：KDD是一个迭代过程，包括：1. 数据清理（去除噪声）；2. 数据集成（多源合并）；3. 数据选择（选取相关数据）；4. 数据变换（汇总或转换）；5. 数据挖掘（提取模式）；6. 模式评估（识别有趣模式）；7. 知识呈现（可视化）。

Q2: 数据挖掘与传统数据库查询处理 (Query Processing) 的区别是什么？

1. 参考答案：
 - 数据库查询是演绎的 (Deductive)，针对具体、明确的数据检索（如“查找具体某个

人”)，结果是确定的数据子集。

- **数据挖掘**是归纳的 (Inductive)，旨在发现隐含的、先前未知的模式或规则（如“这类人通常会买这类商品”），结果是概括性的知识。

Q3: 什么是“分类” (Classification) 与“聚类” (Clustering)，它们的本质区别是什么？

- **参考答案：**
 - **分类**是监督学习，数据已经有类别标签（如“欺诈”vs“正常”），目的是建立模型预测新数据的标签。
 - **聚类**是无监督学习，数据没有标签，目的是根据相似性将数据自动分组。
 - **本质区别：**是否有预定义的类别标签 (Class Label)。

Q4: 请列举三种数据挖掘在商业中的具体应用。

- **参考答案：**
 - **市场篮子分析：**发现产品销售之间的关联，用于货架摆放或捆绑销售。
 - **欺诈检测：**利用信用卡历史行为模型识别异常交易。
 - **客户流失预测：**识别可能流失的客户，采取挽留措施。

Q5: 数据挖掘面临的主要挑战有哪些？

- **参考答案：**
 - 数据量巨大，算法需要具备**可扩展性 (Scalability)**。
 - 数据类型**多样且复杂 (Complex types)**，不仅是关系型数据，还有文本、多媒体等。
 - 数据存在**噪声和不完整性**，需要清理。
 - **隐私保护与数据安全问题**。

二：《数据预处理》

第一部分：为什么要进行数据预处理？(Overview)

核心概念与背景：

- **GIGO 原则：**Garbage In, Garbage Out（垃圾进，垃圾出）。没有高质量的数据，就没有高质量的挖掘结果。
- **现实世界数据的特点：**
 - **脏 (Dirty)**。
 - **不完整 (Incomplete)**：缺少属性值、缺少感兴趣的属性或仅包含汇总数据。
 - **嘈杂 (Noisy)**：包含错误或异常值 (Outliers)。
 - **不一致 (Inconsistent)**：代码或名称存在差异（如日期格式不同）。
- **数据质量的多维度衡量：**

6. 准确性 (Accuracy)
7. 完整性 (Completeness)
8. 一致性 (Consistency)
9. 及时性 (Timeliness)
10. 可信度 (Believability)
11. 附加值 (Value added)
12. 可解释性 (Interpretability)
13. 可访问性 (Accessibility)

KDD 过程中的位置:

数据清理 -> 数据集成 -> 选择 -> 数据变换 -> **数据挖掘** -> 模式评估 -> 知识。

第二部分：数据预处理的主要任务 (Major Tasks)

这部分通常考简答题或选择题，考察对各步骤功能的理解。

2. 数据清理 (Data Cleaning):
 - 任务：填充缺失值、平滑噪声数据、识别或删除异常值、解决不一致问题。
3. 数据集成 (Data Integration):
 - 任务：集成多个数据库、数据立方体或文件。
4. 数据转换 (Data Transformation):
 - 任务：规范化 (Normalization) 和聚合 (Aggregation) 。
5. 数据缩减 (Data Reduction):
 - 任务：获得体积减小但产生相同或相似分析结果的数据集。
6. 数据离散化 (Data Discretization):
 - 任务：数据缩减的一部分，对数值数据特别重要。

第三部分：详细技术与考点解析

1. 数据清理 (Data Cleaning)

A. 如何处理缺失值 (Missing Data)

原因：设备故障、不一致被删除、未输入、被视为不重要等。

处理方法（考点：优缺点对比）：

3. 忽略元组：通常用于类标签 (Class Label) 缺失时。如果每个属性缺失比例很大，这种方法效率低。
4. 手动填写：繁琐，大数据量下不可行。
5. 使用全局常量填充：例如填入 "Unknown" 或 "∞"。缺点：挖掘程序可能误将其视为一个新概念。

6. 使用属性平均值：填入该属性所有非空值的平均值。
7. 使用同类样本的属性均值（更聪明的方法）：例如属于 "Risk=High" 类的样本，用该类中该属性的平均值填充。
8. 使用最可能的值：基于推理（如贝叶斯公式、决策树）预测缺失值。这是最常用的策略。

B. 如何处理噪声数据 (Noisy Data)

噪声定义：测量变量的随机误差或方差。

处理方法：

2. 分箱 (Binning)：（重点计算题考点）

- 步骤：首先对数据进行排序，然后分箱。
- 分区方法：
 - 等深（频率）分箱 (Equal-depth/frequency)：每个箱子包含相同数量的样本。数据扩展性好。
 - 等宽（距离）分箱 (Equal-width/distance)：将范围分为N个等大小的区间。公式： $width = (Max - Min) / N$ 。缺点：受异常值影响大（倾斜数据处理不好）。
- 平滑方法：
 - 按箱均值平滑：箱内所有值替换为该箱的平均值。
 - 按箱中值平滑：箱内所有值替换为该箱的中位数。
 - 按箱边界平滑：箱内所有值替换为最接近的边界值（Min或Max）。

★ 预测考题：分箱计算

题目：给定数据 [4, 8, 15, 21, 21, 24, 25, 28, 34]，使用箱深为3的分箱，并用箱均值平滑。

解答：

1. 排序（已排序）。
2. 分箱（每箱3个）：
 - Bin 1: [4, 8, 15]
 - Bin 2: [21, 21, 24]
 - Bin 3: [25, 28, 34]
3. 均值计算：
 - Mean 1 = $(4+8+15)/3 = 9$
 - Mean 2 = $(21+21+24)/3 = 22$
 - Mean 3 = $(25+28+34)/3 = 29$
4. 平滑结果：
 - Bin 1: [9, 9, 9]
 - Bin 2: [22, 22, 22]
 - Bin 3: [29, 29, 29]

3. 聚类 (Clustering)：检测并删除异常值（孤立点）。

4. 回归 (Regression)：将数据拟合到函数（如线性回归 $y = x + 1$ ）来平滑。

5. 人机结合检查。

2. 数据集成 (Data Integration)

核心问题：

2. 实体识别问题：如何匹配不同源的实体（例如 A.cust-id 是否等于 B.cust-#）。
3. 冗余数据：派生属性（如“年收入”可由“月薪”推导）。可通过相关性分析检测。
4. 数据值冲突：同一实体在不同源的值不同（单位不同，如公制 vs 英制）。

★ 重点公式：字符串相似度与编辑距离 (Edit Distance)

应用：用于模糊匹配不同数据源中的字符串（如拼写错误）。

定义：将模式串 (Pattern, P) 修改为标准串 (Text, W) 所需的最少操作次数。

操作及权重（通常假设）：

- 插入 (Insert)
- 删除 (Delete)
- 修改/替换 (Substitute)
- 交换 (Transpose/Exchange adjacent)

计算公式（递归逻辑）：

PPT中给出了一个递归定义的逻辑（虽然OCR有乱码，但逻辑是经典的动态规划）：

$D(P_m, W_n)$ 表示长度为m的串P和长度为n的串W的距离。

- 若字符相等 ($P_i == W_j$)，代价可能为0或特定值。
- 若不相等，取以下最小者：

3. 删除 P_i 的代价 + $D(P_{i-1}, W_j)$

4. 插入字符的代价 + $D(P_i, W_{j-1})$

5. 替换 P_i 的代价 + $D(P_{i-1}, W_{j-1})$

6. (如果允许交换) 交换代价 + $D(P_{i-2}, W_{j-2})$

相似度公式：

$$Sim(P, W) = 1 - \frac{D(P, W)}{\max(|P|, |W|)}$$

(注意：分母取两者长度的最大值)

★ 预测考题：编辑距离计算

题目：计算 "instenc" 转换为 "instance" 的编辑距离（根据PPT示例）。

解析（PPT Page 22）：

2. 删除 c (在s和t之间) -> "instenc" (1步)
 3. 修改 e 为 a -> "instanc" (1步)
 4. 插入 e 在结尾 -> "instance" (1步)
- 总距离 = 3

3. 数据转换 (Data Transformation)

包括：平滑、聚合、概括（概念分层）、规范化、属性构造。

★ 重点公式：规范化 (Normalization)

这是必考计算题，请务必掌握三种方法。

1. 最小-最大规范化 (Min-Max Normalization)

- 公式：

$$v' = \frac{v - \min_A}{\max_A - \min_A} (\text{new_max}_A - \text{new_min}_A) + \text{new_min}_A$$

- 含义：将数据线性映射到 $[\text{new_min}_A, \text{new_max}_A]$ 区间（通常是 $[0, 1]$ ）。
- 例题：收入属性范围 $[12,000, 98,000]$ 。将 73,600 映射到 $[0, 1]$ 。

$$v' = \frac{73,600 - 12,000}{98,000 - 12,000} (1 - 0) + 0 = \frac{61,600}{86,000} \approx 0.716$$

2. Z-score 规范化 (零均值规范化)

- 场景：当实际的最大/最小值未知，或有异常值时使用。
- 公式：

$$v' = \frac{v - Mean_A}{StdDev_A}$$

(其中 $Mean_A$ 是均值, σ_A 或 $StdDev$ 是标准差)

- 例题: 均值=54,000, 标准差=16,000。值 73,600 的规范化结果?

$$v' = \frac{73,600 - 54,000}{16,000} = \frac{19,600}{16,000} = 1.225$$

3. 小数定标规范化 (Decimal Scaling)

- 公式:

$$v' = \frac{v}{10^j}$$

(其中 j 是使得 $\max(|v'|) < 1$ 的最小整数)

- 例题: 数据范围 -986 到 917。绝对值最大为 986, 需要移动3位小数点 ($j = 3$) 才能小于1。
 - -986 -> -0.986
 - 917 -> 0.917

4. 数据缩减 (Data Reduction)

策略:

5. 数据立方体聚合: 在不同层级汇总数据 (Base cube -> Aggregated cube)。
6. 维规约 (Dimensionality Reduction): 减少属性数量。
 - 特征选择: 选择最小属性子集。
 - 逐步向前选择 (Forward Selection)
 - 逐步向后消除 (Backward Elimination)
 - 决策树归纳 (Decision Tree Induction)
 - PCA (主成分分析): 将数据投影到正交向量上, 适用于数值数据。保留标准差大的维度。
 - 小波变换 (Wavelet): 有损压缩, 保留最强系数。
7. 数值规约 (Numerosity Reduction): 减少数据量。

- 参数方法：回归（线性 $Y = \alpha + \beta X$ ）、对数线性模型。
- 非参数方法：直方图、聚类、采样（SRSWR有放回, SRSWOR无放回, 分层采样）。

★ 重点公式：决策树属性选择 (信息增益)

PPT (Page 31-32) 详细展示了通过计算信息熵 (Entropy) 和增益 (Gain) 来选择最佳属性的过程。

1. 熵 (Entropy) 公式：

$$Entropy(S) = - \sum_{i=1}^m p_i \log_2(p_i)$$

- S : 数据集
- p_i : 第 i 类样本出现的概率

PPT 案例详解：

- 总样本数 14, 类别为 [Responded (9个), Nothing (5个)]

$$Entropy(S) = -\frac{9}{14} \log_2\left(\frac{9}{14}\right) - \frac{5}{14} \log_2\left(\frac{5}{14}\right) = 0.940$$

•

2. 信息增益 (Information Gain) 公式：

$$Gain(S, A) = Entropy(S) - \sum \frac{|S_v|}{|S|} Entropy(S_v)$$

- A : 正在测试的属性（如 District, Income）。
- S_v : 属性 A 取值为 v 的子集。

PPT 案例计算 (Income 属性)：

- **Income=High** (7个样本): 其中 {No: 4, Yes: 3} (注意：这里PPT数据可能有特定分布，根据

PPT Page 32结果) -> $Entropy = 0.9852$

- **Income=Low** (7个样本): 其中 {No: X, Yes: Y} -> $Entropy = 0.5917$
- 计算 **Gain(Income)**:

$$Gain = 0.940 - \frac{7}{14}(0.9852) - \frac{7}{14}(0.5917) = 0.152$$

- **结论**: 比较所有属性的 Gain, Gain 最大的属性作为根节点 (PPT中 District 的 Gain=0.247 > Income, 所以选 District)。

5. 离散化与概念分层 (Discretization)

离散化类型:

- **基于熵的离散化**:
 - 自顶向下, 递归划分。
 - 选择使划分后熵最小的边界点。
 - 停止条件: $Entropy(S) - Entropy_{partition}(S) > \delta$
- 按自然分割法 (3-4-5 规则): (必考操作题)

★ 重点技术: 3-4-5 规则 (The 3-4-5 Rule)

用于将数值范围划分为“自然”的区间 (如 0-100, 200-400 等, 而不是 0-13.5 这种奇怪的数字)。

规则内容:

1. 首先确定数据的最高有效位 (MSD, Most Significant Digit)。
2. **规则 1**: 如果区间在MSD上覆盖 **3, 6, 7, 9** 个不同的值 -> 划分为 **3** 个等宽区间。
3. **规则 2**: 如果区间在MSD上覆盖 **2, 4, 8** 个不同的值 -> 划分为 **4** 个等宽区间。
4. **规则 3**: 如果区间在MSD上覆盖 **1, 5, 10** 个不同的值 -> 划分为 **5** 个等宽区间。

PPT 案例详解 (Page 55):

- 数据范围: $\text{—\$351,976 到 \$4,700,986}$ 。
- **Step 1 找核心范围**: 去掉 5% 的低端和高端异常值。假设得到核心范围:
 $\text{—\$159,876 到 \$1,838,876}$ 。
- **Step 2 确定 MSD**:
 - $m.s.d = 1,000,000$ (百万级)。

- 根据这个量级取整: $\text{Low} = -\$1,000,000$, $\text{High} = \$2,000,000$ 。
 - 范围 $\text{Range} = 2,000,000 - (-1,000,000) = 3,000,000$ 。
 - MSD 的值为 3。
- **Step 3 应用规则:**
 - MSD=3, 根据“3,6,7,9 -> 分3份”规则。
 - 划分步长 = $3,000,000 / 3 = 1,000,000$ 。
 - 得到区间:
 1. $(-1,000,000 - 0)$
 2. $(0 - 1,000,000)$
 3. $(1,000,000 - 2,000,000)$
- **Step 4 递归:** 对每个子区间重复上述步骤。例如 $(0 - 1,000,000)$ 可能被分为5个20万的区间 (因为10覆盖1,5,10规则)。

分类数据的概念分层:

- 指定全序: $\text{Street} < \text{City} < \text{Province} < \text{Country}$
- 根据不同值数量自动生成: 不同值越多的属性, 层级越低 (如 Street 有60万个值 -> 底层; Country 有15个值 -> 高层)。

第四部分: 可能的考试题型预测 (Exam Prediction)

1. 简答题:
 - Q: 请简述数据预处理的四个主要步骤及其目的。
 - Q: 什么是数据清理中的“忽略元组”策略? 它在什么情况下适用, 什么情况下不适用?
 - Q: 比较等宽分箱和等深分箱的优缺点。
2. 计算题 (必须掌握):
 - **Min-Max / Z-score 规范化:** 给一个数, 求转换后的值。
 - **分箱平滑:** 给一组数据, 要求排序、分箱 (等宽或等深), 并计算平滑后的结果。
 - **信息增益:** 给一个小表格 (类似买电脑或PPT中的Response案例), 计算某属性的信息增益。
 - **编辑距离:** 给两个短单词, 写出变换步骤和距离。
3. 应用/分析题:
 - **3-4-5 规则应用:** 给出一个具体的数值范围 (如 $\text{Min}=-350$, $\text{Max}=850$), 请展示如何使用3-4-5规则进行第一层级的划分。
 - 思路: $\text{Range} = 1200$ 。取整可能看作 1200。MSD为12 (或者看作覆盖了10左右)。若看作12, 接近10, 分5份; 或者将范围扩大到-400到+1000? 需根据

PPT逻辑：找MSD。例如 -400 到 800，Range=1200，3/6/7/9 规则不适用。如果在 1,5,10 规则下，可能分5份。这题需要灵活根据 "Most Significant Digit" 的个数来套用规则。

4. 抽样方法辨析：

- 区分 SRSWOR (无放回简单随机) 和 SRSWR (有放回简单随机)。
- 区分 聚类抽样 (Cluster) 和 分层抽样 (Stratified)。
 - *Stratified*: 层内差异小，层间差异大（如按年龄分层）。
 - *Cluster*: 群体之间差异小（如按班级抽样）。

三：《数据挖掘：数据仓库与OLAP技术》

第一部分：核心概念与定义 (基础必考)

1. 数据挖掘与KDD过程的位置

3. **KDD过程 (Knowledge Discovery in Databases)**: 数据挖掘是知识发现过程的核心步骤。
4. **流程顺序**: 数据库 -> 数据集成 -> 数据清理 -> 数据仓库 -> 选择 -> 任务相关数据 -> 数据挖掘 -> 模式评估 -> 知识¹
5. **地位**: 数据仓库是数据挖掘的重要预处理平台，为其提供高质量的数据基础。

2. 什么是数据仓库 (Data Warehouse)?

定义 (W.H. Inmon): 数据仓库是一个面向主题的 (Subject-Oriented)、集成的 (Integrated)、随时间变化的 (Time-Variant)、非易失的 (Non-Volatile) 数据集合，用于支持管理层的决策过程²。

四大核心特征详解 (重点辨析题):

- **面向主题 (Subject-Oriented)**:
 - 围绕主要主题（如客户、产品、销售）组织，而非围绕应用（如发票处理）。
 - 专注于决策分析，排除对决策无用的操作型数据³。
- **集成 (Integrated)**:
 14. 从多个异构数据源（关系库、平面文件、在线交易记录）构建。
 15. 必须进行**数据清理**和**数据集成**。需统一命名约定、编码结构、属性度量（如货币单位、日期格式）⁴。

- **随时间变化 (Time-Variant):**
 - 时间跨度长（历史视角，过去5-10年），不同于操作型数据库的“当前值”。
 - 每个关键结构都包含时间元素（显式或隐式）⁵。
- **非易失性 (Non-Volatile):**
 - 数据一旦进入仓库，通常不再更新（不进行实时修改）。
 - 仅需两种操作：**初始加载 (Loading)** 和 **访问 (Access)**。
 - 不需要复杂的事务处理、恢复和并发控制机制⁶。

3. OLTP vs OLAP (对比分析题)

这是考试中极其常见的对比题，建议直接背诵表格差异。

特性	OLTP (联机事务处理)	OLAP (联机分析处理)
面向对象	客户、文员、IT专业人员	高层管理者、知识工作者、分析师
功能	日常运营 (银行、库存、销售)	决策支持、分析
数据库设计	面向应用 (ER模型)	面向主题 (星型/雪花模型)
数据内容	当前的、详细的、分散的	历史的、汇总的、集成的
视图	当前、本地	演进、集成
访问模式	原子性事务，读/写	只读，复杂查询
操作量级	短事务，处理少量记录	长查询，扫描数百万条记录
数据库大小	MB 到 GB 级	GB 到 TB 级
度量指标	交易吞吐量	查询吞吐量、响应时间
⁷		

为什么要分离？

9. **数据原因:** 决策需要历史和集成数据, 而OLTP通常只保留当前数据且数据源异构⁸。

第二部分：多维数据模型与架构 (建模大题)

1. 数据立方体 (Data Cube)

4. **定义:** 数据仓库基于多维数据模型，数据以“立方体”形式查看。
4. **组成:**
 - **维度 (Dimensions):** 观察数据的角度 (如: 时间、商品、地点)。
 - **维度表:** 包含维度的描述 (如: 商品名、品牌)。
 - **事实表 (Fact Table):** 包含度量值 (数值, 如销售额) 和维度的键⁹。
5. **格 (Lattice) 结构:**
 - **基底长方体 (Base Cuboid):** 包含所有维度的最详细数据 (n-D)。
 - **顶点长方体 (Apex Cuboid):** 0-D, 表示所有数据的总汇总 (Total/All)

2. 概念模型 (Schema) (画图/区分题)

- ### 9. 星型模式 (Star Schema):
1. **结构:** 一个大的中心事实表，周围连接一组小的维度表。
 2. **特点:** 维度表未规范化（存在冗余），但存取效率高，易于理解¹¹¹¹¹¹¹¹。
- ### 10. 雪花模式 (Snowflake Schema):
- **结构:** 星型模式的变体，维度表被进一步规范化（拆分为更小的表）。
 - **特点:** 减少存储空间，易于维护，但连接 (Join) 操作多，查询效率可能降低，浏览维度较复杂¹²¹²¹²¹²¹²¹²¹²¹²¹²。
- ### 11. 事实星座 (Fact Constellation):
- **结构:** 多个事实表共享维度表。
 - **应用:** 用于复杂的企业级仓库¹³¹³¹³¹³。

3. 度量的分类 (Measures)

根据聚合函数的性质分类:

2. **分布式 (Distributive):** 可以将数据分片计算后直接合并。

- 5. 例: count(), sum(), min(), max()。
- 3. 代数式 (Algebraic): 需要有限个参数 (如Sum和Count) 组合计算。
 - 例: avg() (需要sum和count), standard_deviation()。
- 4. 整体式 (Holistic): 必须基于所有数据整体计算, 无法分片。
 - 例: median() (中位数), mode() (众数), rank()¹⁴。

4. 概念分层 (Concept Hierarchies)

- 定义了数据从低层 (详细) 到高层 (抽象) 的映射。
- 模式层次 (Schema Hierarchy): 街道 < 城市 < 省份 < 国家。
- 集合分组 (Set-grouping): {1..10} < 便宜, {11..20} < 适中¹⁵。

第三部分：OLAP 操作与实现 (操作应用题)

1. 典型 OLAP 操作

- 上卷 (Roll-up / Drill-up): 汇总数据。
 - 方法: 沿层级向上 (城市->国家) 或 减少维度 (从3D变为2D)。
- 下钻 (Drill-down): 深入细节。
 - 方法: 沿层级向下 (季度->月) 或 引入新维度。
- 切片 (Slice): 在某一维上选定一个值 (选定“年=2024”), 将多维降维。
- 切块 (Dice): 在两个或多个维上选定区间 (选定“年=2024”且“地区=美国”), 得到子立方体。
- 旋转 (Pivot): 改变可视化视角 (交换行列轴)¹⁶。
- 钻取 (Drill-across): 涉及多个事实表。
- 钻透 (Drill-through): 穿过立方体直达后端关系表SQL¹⁷。

2. 数据仓库架构 (三层)

- 底层 (仓库数据库服务器): 关系型数据库 (RDBMS) 或多维数据库, 用于存储数据。
- 中间层 (OLAP 服务器):
 - ROLAP (Relational OLAP): 基于关系库, 使用中间件将OLAP操作转为SQL。扩展性好, 适合大数据量。
 - MOLAP (Multidimensional OLAP): 基于数组 (稀疏矩阵), 直接存储多维数据。查询极快, 但受限于稀疏性。
 - HOLAP (Hybrid OLAP): 混合模式。详细数据用ROLAP, 汇总数据用MOLAP。
- 顶层 (前端工具): 查询、报表、分析、数据挖掘工具¹⁸¹⁸¹⁸¹⁸。

3. 数据仓库模型

- 企业仓库: 覆盖全组织所有主题。
- 数据集市 (Data Mart): 部门级，特定主题（如营销部）。分为独立和从属（来自仓库）。
- 虚拟仓库: 基于操作数据库的视图集合¹⁹。

第四部分：关键公式与计算 (计算大题预测)

1. 数据立方体长方体数量计算公式

公式:

对于一个 n 维的数据立方体，如果第 i 个维度有 L_i 个概念层级（不包含"ALL"层），那么可以生成的长方体（Cuboid）总数 T 为:

$$T = \prod_{i=1}^n (L_i + 1)$$

公式解析:

- 8. n : 维度的数量。
- 9. L_i : 第 i 个维度的层级数（例如：时间维有“日-月-年”，则 $L = 3$ ）。
- 10. $+1$: 代表每个维度都可以进行汇总到最高层（即 "ALL" 或 "Total" 层）。
- 11. 这个公式计算的是在这个多维空间中，所有可能的聚合组合（Group-by）的数量。

例题预测:

题目: 假设一个数据仓库有3个维度:

- 2. 时间 (Time): 层级为 天 < 月 < 季 < 年 (共4层)。
 - 3. 地点 (Location): 层级为 城市 < 省 < 国家 (共3层)。
 - 4. 产品 (Product): 层级为 商品 < 类别 (共2层)。
- 请问该数据立方体一共包含多少个长方体?

解答:

2. $L_{time} = 4$

3. $L_{location} = 3$

4. $L_{product} = 2$

5. 总数

$$T = (4 + 1) \times (3 + 1) \times (2 + 1) = 5 \times 4 \times 3 = 60$$

个长方体。

2. 位图索引 (Bitmap Indexing)

原理: 对某列的每个唯一值建立一个位向量 (Bit Vector) 。

适用性: 适用于**基数低** (Low Cardinality, 即唯一值很少) 的列, 如性别、职业类型。

优势: 位运算 (AND, OR) 速度极快, 且压缩率高²⁰。

例题预测:

题目: 某表有列 "Region" (值: Asia, Europe, USA) 和 "Type" (值: Retail, Dealer)。给定记录 R1=(Asia, Retail), R2=(Europe, Dealer)。请写出 R1 的位图表示。

解答:

2. Region 位图: Asia向量位为1, Europe为0, USA为0。

3. Type 位图: Retail向量位为1, Dealer为0。

3. 连接索引 (Join Index)

原理: 预先计算好两个表 (如维度表和事实表) 连接的结果, 存储为 (RID_A, RID_B) 对。

作用: 避免在查询时进行昂贵的关系连接操作, 加速星型模式中的连接²¹。

第五部分：高级话题 (不遗漏任何考点)

1. 发现驱动的探索 (Discovery-Driven Exploration)

- **背景:** 搜索空间太大，用户难以手动发现异常。
- **方法:** 系统自动预计算异常指标，引导用户注意异常数据。
- **异常 (Exception):** 实际值与基于统计模型的**预期值**有显著差异。
- **视觉提示:** 使用颜色（如背景色）标示异常程度²²。

2. OLAM (Online Analytical Mining)

- **定义:** 在线分析挖掘，将OLAP与数据挖掘结合。
- **必要性:** 数据仓库数据质量高；现有的OLAP设施完善；需要进行探索性数据分析。
- **架构:** 在OLAP引擎之上增加OLAM引擎，支持在线选择挖掘函数²³。

3. 数据仓库后端流程

- **提取 (Extraction):** 获取数据。
- **清理 (Cleaning):** 纠错。
- **转换 (Transformation):** 格式转换。
- **加载 (Loading):** 排序、汇总、构建索引。
- **刷新 (Refreshing):** 传播更新²⁴。

4. 元数据 (Metadata)

- **定义:** 关于数据的数据。包含模式、视图、维度定义、数据血缘（来源）、数据刷新规则、以及业务术语等²⁵。

第六部分：必考题目预测与标准答案

题目 1: 简述 OLTP 和 OLAP 的主要区别。（10分）

答案要点: (请参考第一部分表格，必须答出以下几点)

- **用户:** OLTP是操作人员/IT；OLAP是决策者/分析师。
- **数据:** OLTP是当前、详细数据；OLAP是历史、汇总数据。
- **设计:** OLTP面向应用(ER)；OLAP面向主题(星型)。
- **访问:** OLTP是读写事务；OLAP是只读复杂查询。
- **目标:** OLTP关注交易处理效率；OLAP关注决策支持。

题目 2: 什么是星型模式？它与雪花模式有何不同？（10分）

答案要点:

- **星型模式:** 包含一个中心事实表和一组非规范化的维度表，像星星形状。
- **区别:**
 - **规范化:** 雪花模式对维度表进行了规范化（拆分），星型没有。
 - **存储:** 雪花模式冗余少，节省空间。
 - **性能:** 星型模式连接少，查询通常更快；雪花模式连接多，查询可能慢。
 - **易用性:** 星型模式结构简单，更适合直接浏览。

题目 3: 解释数据立方体中“整体式 (Holistic)”度量的含义并举例。（5分）

答案要点:

- 整体式度量是指不能通过将数据分片计算再合并来得到的度量，必须对整个数据集进行计算。
- 它没有恒定的存储限制。
- **例子:** 中位数 (Median)、众数 (Mode)、排名 (Rank)。
- (对比: Sum是分布式的, Avg是代数式的)。

题目 4: 在数据仓库架构中，ROLAP 和 MOLAP 有什么区别？（5分）

答案要点:

- **ROLAP:** 使用关系型数据库存储，通过中间件支持OLAP。扩展性好，处理大数据能力强，但速度可能不如MOLAP。
- **MOLAP:** 使用基于数组的多维存储引擎（稀疏矩阵）。查询速度快（预计算），但受限于数据的稀疏性和存储大小。

题目 5: 计算题：给定维度层级数计算长方体总数。

(请参考第四部分的公式 $T = \prod (L_i + 1)$ 进行回答)

四：分类和预测

模块一：分类与预测基础 (PPT 1-10)

【核心概念总结】

- **KDD过程 (Knowledge Discovery in Databases):**
 - 数据挖掘是知识发现的核心步骤。
 - **流程:** 数据库 -> 数据集成 -> 数据仓库 -> 选择任务相关数据 -> 数据挖掘 -> 模式评估 -> 知识。

- **分类 vs 预测 (Classification vs. Prediction):**
 - 16. **分类 (Classification):**
 - 预测类别标签 (Class Label) [离散值/无序]。
 - 过程: 构建模型 (基于训练集) -> 使用模型 (分类新数据)。
 - 应用: 信用审批、目标营销、医疗诊断。
 - 17. **预测 (Prediction):**
 - 建立连续值函数模型, 预测未知或缺失的值 [连续值]。
 - 18. **监督学习 vs 无监督学习:**
 - **监督学习 (分类):** 训练数据有类别标签 (Labelled)。
 - **无监督学习 (聚类):** 训练数据无标签, 目的是发现数据中的内在结构或聚类。
- **分类的两步过程:**
 - **第一步: 模型构建 (训练)**
 - 使用训练数据集 (Training Set)。
 - 假定每个样本属于一个预定义的类。
 - 输出: 分类规则、决策树或数学公式。
 - **第二步: 模型使用 (分类/测试)**
 - 使用测试数据集 (Test Set) 评估准确率。
 - **注意:** 测试集必须独立于训练集, 否则会导致**过拟合 (Overfitting)**。
 - 准确率 = 模型正确分类的样本百分比。
- **数据准备 (Data Preparation):**
 - **数据清理:** 处理噪声、缺失值。
 - **相关性分析 (特征选择):** 删除不相关或多余属性。
 - **数据转换:** 概括或规范化 (Normalization)。
- **分类方法的评估标准:**
 - 3. **预测准确性。**
 - 4. **速度** (构建时间、使用时间)。
 - 5. **稳健性** (处理噪声/缺失值的能力)。
 - 6. **可扩展性** (处理海量数据、磁盘驻留数据的能力)。
 - 7. **可解释性** (模型提供的洞察力、规则优劣)。

【考题预测】

- 4. **简答题:** 简述分类和预测的区别?
 - 答: 分类旨在预测离散的类别标签, 而预测旨在建立连续值函数模型以预测未知或缺失的数值。分类是监督学习, 数据有标签; 预测通常指回归分析。
- 5. **判断题:** 为了获得最高的准确率, 应该使用训练集来测试模型?
 - 答: 错。测试集必须独立于训练集, 否则无法评估模型对未见数据的泛化能力, 且容易过拟合。

模块二: 决策树归纳 (Decision Tree Induction) (PPT 11-31)

【核心知识点】

6. 树结构:

- 内部节点: 表示对属性的测试。
- 分支: 代表测试结果。
- 叶节点: 代表类标签或类分布。

7. 构建过程 (贪婪算法/自顶向下):

- 开始时所有样本在根节点。
- 递归地根据属性选择测度 (Attribute Selection Measure) 划分样本。
- 停止条件:
 - 节点样本属于同一类。
 - 没有剩余属性 (使用多数投票)。
 - 没有剩余样本。

8. 属性选择测度:

1. 信息增益 (Information Gain) -> 算法: ID3, C4.5。
2. 基尼系数 (Gini Index) -> 算法: CART, IBM IntelligentMiner。

【公式详解与计算例题】(必考重点)

1. 信息增益 (Information Gain) - ID3/C4.5

原理: 选择能使熵 (混乱度) 减少最多的属性进行分裂。

5. 公式 1: 数据集 S 的熵 (Entropy)

$$I(p, n) = -\frac{p}{p+n} \log_2 \frac{p}{p+n} - \frac{n}{p+n} \log_2 \frac{n}{p+n}$$

- p : 正例样本数, n : 负例样本数。

- 注: 如果是多分类, 公式为 $Entropy(S) = -\sum p_i \log_2(p_i)$ 。

6. 公式 2: 属性 A 对数据集 S 划分后的期望熵 (Expected Information)

$$E(A) = \sum_{i=1}^v \frac{p_i + n_i}{p+n} I(p_i, n_i)$$

- 属性 A 有 v 个不同的值, 将 S 划分为 v 个子集。

- $\frac{p_i + n_i}{p+n}$ 是第 i 个分支的权重。

7. 公式 3: 信息增益 (Gain)

$$Gain(A) = I(p, n) - E(A)$$

★ 计算例题 (PPT 19-20 "Play Tennis"案例):

- 背景: 总样本 14 个, 9 个 Yes (Play), 5 个 No (Don't Play)。
- Step 1: 计算总熵

$$Entropy(S) = -\frac{9}{14} \log_2 \frac{9}{14} - \frac{5}{14} \log_2 \frac{5}{14} = 0.940$$

- Step 2: 计算属性 "Income" (假设) 的增益
 - 假设 Income 有 High, Low 两个值。
 - Income=High: 7个样本 (0 Yes, 7 No? PPT数据可能有误, 按PPT 20页逻辑):
 - PPT 20页数据: High (7个样本), Low (7个样本)。
 - High分支熵 = 0.9852, Low分支熵 = 0.5917。
 - 计算期望熵:

$$E(Income) = \frac{7}{14} \times 0.9852 + \frac{7}{14} \times 0.5917 = 0.788$$

- 计算增益:

$$Gain(Income) = 0.940 - 0.788 = 0.152$$

- 结论: 比较所有属性的 Gain, 选择最大的属性作为分裂节点。

2. 基尼系数 (Gini Index) - CART

原理: 用于度量数据的不纯度。

5. 公式:

$$Gini(S) = 1 - \sum_{j=1}^C p_j^2$$

- p_j 是类 j 在 S 中的相对频率。

6. 分裂后的基尼系数:

$$Gini_{split}(S) = \frac{n_1}{n}Gini(S_1) + \frac{n_2}{n}Gini(S_2)$$

7. 选择使 Gini 最小的属性。

【决策树进阶】

4. 避免过拟合 (Overfitting):

- 原因：噪声、异常值、样本太少导致树太复杂。
- 预修剪 (Pre-pruning)**：在完全生长前停止（例如：设定阈值，如果增益小于阈值则停止）。难点在于选择阈值。
- 后修剪 (Post-pruning)**：先长成完全树，再自底向上剪枝。使用验证集 (Validation Set) 或 MDL 原则来决定最佳树。

5. 规则提取：

- 将树转化为 "IF-THEN" 规则。每条从根到叶的路径对应一条规则。规则更易于人类理解。

6. 扩展性问题：

- RainForest 算法**：构建 AVC-list (Attribute-Value-Class)，将可扩展性与树的质量标准分离，只需扫描数据库一次即可在内存中构建。
- 其他算法：SLIQ, SPRINT。

模块三：贝叶斯分类 (Bayesian Classification) (PPT 32-43)

【核心概念】

- 统计学基础：概率学习，计算假设的后验概率。
- 优点：高准确率，可增量学习。

【公式详解】(必考)

1. 贝叶斯定理 (Bayes Theorem)

$$P(H|X) = \frac{P(X|H)P(H)}{P(X)}$$

- X ：数据样本（证据）。
- H ：假设（例如：样本属于类 C）。

- $P(H|X)$: 后验概率 (Posterior) -> 我们要求的。
- $P(H)$: 先验概率 (Prior)。
- $P(X|H)$: 似然度 (Likelihood) -> 在假设成立下观察到 X 的概率。
- $P(X)$: 证据概率 (常数, 比较时可忽略)。

2. 朴素贝叶斯分类 (Naive Bayes Classifier)

假设：属性之间条件独立 (Class Conditional Independence)。即：

$$P(X|C) = P(x_1|C) \times P(x_2|C) \times \cdots \times P(x_n|C)$$

★ 计算例题 (PPT 37-38 网球案例)：

- 任务：分类新样本 $X = \langle Rain, Hot, High, False \rangle$
- 已知： $P(p) = 9/14$ (Play), $P(n) = 5/14$ (Not Play)。
- 计算 $P(X|Yes)$:
 - $P(Rain|Yes) = 3/9$
 - $P(Hot|Yes) = 2/9$
 - $P(High|Yes) = 3/9$
 - $P(False|Yes) = 6/9$
 - 乘积：

$$P(X|Yes) \times P(Yes) = (3/9 \times 2/9 \times 3/9 \times 6/9) \times (9/14) = 0.010582$$
- 计算 $P(X|No)$:
 - $P(Rain|No) = 2/5$
 - $P(Hot|No) = 2/5$
 - $P(High|No) = 4/5$
 - $P(False|No) = 2/5$
 - 乘积：

$$P(X|No) \times P(No) = (2/5 \times 2/5 \times 4/5 \times 2/5) \times (5/14) = 0.018286$$

- 结论: $0.018 > 0.010$, 分类为 **No (Don't Play)**。

【贝叶斯信念网络 (Bayesian Belief Networks)】

- 解决朴素贝叶斯“独立性假设”在现实中不成立的问题。
- 使用图形模型 (DAG) 描述变量间的因果关系。
- 每个节点有一个条件概率表 (CPT)。

模块四：神经网络 (Neural Networks) (PPT 42-45)

【核心知识】

- **多层感知器 (MLP)**: 输入层、隐藏层、输出层。
- **特点**: 准确率高, 对噪声鲁棒, 但训练时间长, 模型难以理解 (黑盒)。
- **工作原理**:
 - 初始化权重。
 - **前向传播**: 计算输入加权和 -> 激活函数 -> 输出。
 - **反向传播 (Backpropagation)**: 计算误差 -> 更新权重。

【权重更新公式】 (PPT 45页关键公式)

- 输出节点 j 的误差 (Err_j):

$$Err_j = O_j(1 - O_j)(T_j - O_j)$$

- O_j : 实际输出, T_j : 目标值 (True value)。

- 隐藏节点 j 的误差 (Err_j):

$$Err_j = O_j(1 - O_j) \sum_k (Err_k w_{jk})$$

- 来自下一层的误差加权和。

- 权重更新 (w_{ij}):

$$w_{ij} = w_{ij} + (l)Err_j O_i$$

$$\theta_j = \theta_j + (l)Err_j$$

- l : 学习率 (Learning rate)。
- θ : 偏置 (Bias)。

模块五：其他分类方法 (PPT 46-57)

2. **k-最近邻 (k-NN)**:
 - **懒惰学习 (Lazy Learning)**: 不预先构建模型，预测时才计算。
 - 计算查询点与所有训练点的欧几里得距离，取最近的 k 个。
 - 如果是分类：投票；如果是预测：取平均。
 - **缺点**: 计算量大，受无关属性影响（维数灾难）。
3. **基于案例的推理 (CBR)**:
 - 使用符号表示（非欧几里得距离）。
 - 解决新问题时检索旧案例并进行调整（Adaptation）。
4. **遗传算法 (Genetic Algorithms)**:
 - 基于进化论（适者生存）。
 - 种群 -> 选择 -> 交叉 (Crossover) -> 变异 (Mutation)。
5. **粗糙集 (Rough Sets)**:
 - 使用上近似 (Upper Approximation) 和下近似 (Lower Approximation) 来定义类。
6. **模糊集 (Fuzzy Sets)**:
 - 允许“部分归属”，隶属度在 0.0 到 1.0 之间。
 - 解决边界模糊的问题（例如：收入“有些高”）。

模块六：预测 (Prediction/Regression) (PPT 55-62)

1. **线性回归 (Linear Regression)**:
 - 公式: $Y = \alpha + \beta X$ 。
 - 使用最小二乘法 (Least Squares) 估计参数。
2. **多元回归**:

$$Y = b_0 + b_1 X_1 + b_2 X_2 + \dots$$

3. 非线性回归：
 - 可转换为线性模型处理（如对数线性模型）。
4. 局部加权回归：
 - 在查询点附近构造局部近似，距离越近权重越高。

模块七：评估与提升 (Evaluation) (PPT 63-67)

1. 评估方法：
 - **Holdout**: 2/3 训练, 1/3 测试。
 - **交叉验证 (Cross-validation)**: k-fold (k折)。将数据分k份，轮流做测试集，取平均准确率。适用于中等规模数据。
 - **Bootstrap**: 有放回采样 (63.2% 规则)。适用于小数据集。
2. 集成方法 (Ensemble Methods):
 - **Bagging**: 多数投票。
 - **Boosting**:
 - 学习一系列分类器。
 - 后续分类器更关注被前一个分类器错分的样本（增加其权重）。
 - 最终结果是加权投票。

【综合考题预测与答题技巧】

1. 计算题 (必须掌握)

- **题目类型**: 给出一个小的数据集（如PPT中的网球数据或房屋数据），要求构建决策树的根节点，或者使用朴素贝叶斯预测某一样本。
- **决策树解题步骤**:
 1. 列出 Info(D) 公式并计算总熵。
 2. 针对每个属性，计算 Expected Info (E) 和 Gain。
 3. 比较 Gain，选最大的作为根。
 4. **注意**: 写出 log 的计算过程（通常考卷会给出 log2 的值或允许保留 log）。
- **朴素贝叶斯解题步骤**:
 1. 写出公式: $P(C|X) \propto P(X|C)P(C)$ 。
 2. 分别计算每个特征在各类别下的条件概率 $P(x_i|C_j)$ 。
 3. 相乘得到最终概率值进行比较。
 4. **注意**: 如果有概率为0（零频率问题），理论上应使用拉普拉斯平滑（虽然PPT未详细

展开，但需留意分母为0的情况）。

2. 简答/论述题

- 问：懒惰学习（k-NN）与积极学习（决策树/贝叶斯）的区别？
 - 答：(PPT 54)
 - 积极学习：在接受查询前构建全局模型；训练慢，预测快。
 - 懒惰学习：直到查询时才处理数据；训练快（零时间），预测慢；能构建局部近似，假设空间更丰富。
- 问：如何处理决策树的过拟合？
 - 答：使用预修剪（提前停止生长）或后修剪（剪去由于噪声生成的分支，使用验证集评估）。
- 问：神经网络的优缺点？
 - 答：优点是准确率高、对噪声鲁棒、支持连续/离散输出；缺点是训练时间长、模型难以解释（黑盒）、难融入领域知识。

3. 概念辨析

- 分类 vs 聚类：有标签 vs 无标签。
- Bagging vs Boosting：Bagging是并行投票，Boosting是串行加权（关注错题）。

五：数据挖掘：聚类分析

第一部分：聚类分析基础 (Overview)

1. 什么是聚类分析？

6. 定义：将物理或抽象对象的集合分组成多个类（Cluster）的过程。
7. 目标：
 1. 类内相似度高（Intra-class similarity is high）。
 2. 类间相似度低（Inter-class similarity is low）。
8. 应用领域：
 - 模式识别、空间数据分析（GIS专题地图、检测空间聚类）。
 - 图像处理。
 - 经济科学（市场研究，发现客户群）。
 - WWW（文档分类、博客访问模式分析）。
9. 具体案例：
 19. 营销：发现不同客户群体，制定针对性计划。
 20. 土地利用：识别相似土地利用区域。
 21. 保险：识别高索赔成本群体。
 22. 城市规划：根据房型、价值、位置分组。
 23. 地震研究：震中聚集分析。

2. 聚类算法的要求

- 可扩展性 (Scalability): 能处理大规模数据。
- 处理不同属性类型: 不仅是数值型, 还有二元、分类、序数等。
- 发现任意形状的聚类: 不仅仅是球形。
- 对输入参数的最小领域知识要求。
- 处理噪声和异常值的能力。
- 对输入记录顺序不敏感。
- 高维度性。
- 基于约束的聚类。
- 可解释性和可用性。

3. 数据结构

- 数据矩阵 (Data Matrix): $n \times p$ 矩阵 (n 个对象, p 个属性), 用于存储原始数据。
 - 结构: 行代表对象, 列代表属性。
- 相异度矩阵 (Dissimilarity Matrix): $n \times n$ 矩阵, 存储对象间的差异/距离。
 - 结构: $d(i, j)$ 表示对象 i 和 j 的距离, 通常是对角阵, $d(i, i) = 0$ 。

第二部分: 数据类型与距离度量 (Data Types & Distance Measures)

核心考点: 如何计算不同类型变量间的距离。

1. 区间标度变量 (Interval-Scaled Variables)

- 特征: 连续测量, 线性标度 (如重量、高度)。
- 标准化 (Standardization):

- 计算平均绝对偏差 $S_f = \frac{1}{n}(|x_{1f} - m_f| + \cdots + |x_{nf} - m_f|)$,

其中 m_f 是均值。

- 计算 Z-score: $z_{if} = \frac{x_{if} - m_f}{S_f}$ 。
- 注: 使用平均绝对偏差比标准差更稳健。

- 距离公式:

- 闵可夫斯基距离 (Minkowski Distance):

$$d(i, j) = \sqrt[q]{|x_{i1} - x_{j1}|^q + \cdots + |x_{ip} - x_{jp}|^q}.$$

- 当 $q = 1$: 曼哈顿距离 (Manhattan) $\rightarrow |x_{i1} - x_{j1}| + \dots$
- 当 $q = 2$: 欧几里得距离 (Euclidean) $\rightarrow \sqrt{(x_{i1} - x_{j1})^2 + \dots}$

9. 特性: 非负性、同一性($d(i, i) = 0$)、对称性、三角不等式。

2. 二元变量 (Binary Variables)

3. 列联表:

- a : i 和 j 都为1; b : i 为1, j 为0; c : i 为0, j 为1; d : i 和 j 都为0。

4. 对称二元变量 (Symmetric): 0和1同等重要 (如性别)。

- 1. 简单匹配系数 (Simple Matching Coefficient): $d(i, j) = \frac{b+c}{a+b+c+d}$ 。

5. 非对称二元变量 (Asymmetric): 状态1 (出现) 比状态0 (不出现) 更重要 (如疾病检测)。

- Jaccard 系数: $d(i, j) = \frac{b+c}{a+b+c}$ (忽略 d , 即双0的情况)。

3. 名义变量 (Nominal Variables)

- 特征: 无序分类 (如颜色: 红、黄、蓝)。

- 方法1: 简单匹配。 m 为匹配数, p 为总变量数。 $d(i, j) = \frac{p-m}{p}$ 。
- 方法2: 转换为多个二元变量 (One-hot编码)。

4. 序数变量 (Ordinal Variables)

- 特征: 有序 (如等级: 优、良、差)。
- 处理:

- 3. 将排位 $r_{if} \in \{1, \dots, M_f\}$ 映射到 $[0, 1]$ 区间: $z_{if} = \frac{r_{if}-1}{M_f-1}$ 。
- 4. 视为区间标度变量计算距离。

5. 比率标度变量 (Ratio-Scaled Variables)

- 8. 特征: 非线性标度, 指数增长 (如细菌生长)。
- 9. 处理: 进行对数变换 $y_{if} = \log(x_{if})$, 然后视为连续数据。

6. 混合类型 (Mixed Types)

- 公式:
$$d(i, j) = \frac{\sum_{f=1}^p \delta_{ij}^{(f)} d_{ij}^{(f)}}{\sum_{f=1}^p \delta_{ij}^{(f)}}$$
 - $\delta_{ij}^{(f)}$: 指示符, 如果该属性缺失或不对称二元均为0, 则为0, 否则为1。
 - $d_{ij}^{(f)}$: 根据属性类型计算归一化距离 (0到1之间)。

第三部分：主要聚类方法与算法 (Clustering Methods)

PPT将聚类方法分为五大类：

1. 划分方法 (Partitioning Methods)

构建 k 个分区, 每个分区代表一个簇。

- K-Means (K-均值):**
 - 步骤: 1. 随机选 k 个种子点; 2. 对象分派到最近中心; 3. 重新计算质心; 4. 重复直到收敛。
 - 优点: 相对高效 $O(tkn)$ 。
 - 缺点: 需预设 k ; 对噪声/异常值敏感; 只能发现凸形簇; 受初始值影响 (局部最优)。
- K-Medoids (K-中心点):**
 - PAM (Partitioning Around Medoids):** 用实际对象代表簇。计算总交换成本 TC_{ih} 。如果 $TC < 0$, 则替换中心点。适用于小数据。
 - CLARA:** 基于抽样的PAM, 适用于大数据。
 - CLARANS:** 随机搜索的CLARA, 在图中搜索局部最优。

2. 层次方法 (Hierarchical Methods)

对数据进行层次分解, 形成树状结构 (Dendrogram)。

- AGNES (凝聚):** 自底向上, 每次合并距离最近的两个簇。
- DIANA (分裂):** 自顶向下, 初始为一个大簇, 逐渐分裂。
- 改进算法:
 - BIRCH (1996):** 使用 **CF树 (Cluster Feature Tree)**。

■ **CF向量:** $CF = (N, LS, SS)$ 。 N = 点数, LS = 线性和, SS = 平

方和。

- **特点**：CF具有可加性。只需扫描一次数据库。只适用于数值型数据，对顺序敏感。
- **CURE (1998)**：使用多个代表点，并将点向中心收缩 (Shrinking)。
 - **优点**：能适应非球形簇，抗异常值。
- **ROCK (1999)**：针对分类数据。
 - 基于**链接 (Link)** 概念 (共同邻居数)，而非距离。
- **CHAMELEON (1999)**：动态建模。
 - 结合图划分和层次聚类。合并标准：互连性 (Interconnectivity) 和 紧密性 (Closeness)。

3. 基于密度的方法 (Density-based Methods)

基于连通性和密度函数，能发现任意形状的簇，抗噪声。

- **DBSCAN**:

- **核心参数**： ϵ (半径), $MinPts$ (最小点数)。
- **概念**:
 - **核心点 (Core object)**: 邻域内点数 $\geq MinPts$ 。
 - **直接密度可达 (Directly density-reachable)**: 在核心点邻域内。
 - **密度可达 (Density-reachable)**: 通过核心点链传播。
 - **密度相连 (Density-connected)**: 两点都能被第三点密度可达。
- **算法**: 从任意点开始，若是核心点则扩展簇，否则标记为噪声。

- **OPTICS**:

- 不显式生成簇，而是生成**簇排序 (Cluster Ordering)**。
- **核心距离 (Core Distance)** & **可达距离 (Reachability Distance)**。
- 解决了DBSCAN对参数敏感的问题。

- **DENCLUE**:

- 基于**影响函数 (Influence Function)** (如高斯核)。
- 簇由**密度吸引子 (Density Attractors)** (局部最大值) 定义。

4. 基于网格的方法 (Grid-based Methods)

将空间量化为有限网格单元。

- **STING (Statistical Information Grid)**:

- 多分辨率，层级结构。
- 预计算每个单元的统计信息 (count, mean, std, min, max, dist)。
- 优点：查询快，易并行。缺点：边界是水平/垂直的。

- **WaveCluster**:

- 使用**小波变换 (Wavelet Transform)**。
- 低频部分识别簇，高频部分去除噪声。

- 能处理任意形状，复杂度 $O(N)$ 。

5. 基于模型的方法 (Model-based Methods)

假设数据由某种数学模型生成。

- 统计方法：
 - **COBWEB**: 概念聚类，增量式构建分类树。使用分类效用 (Category Utility)。
 - **AutoClass**: 贝叶斯统计。
- 神经网络：
 - 竞争学习 (Competitive Learning)。
 - **SOM (自组织映射)**: 可视化高维数据，神经元竞争获胜。

第四部分：异常值发现 (Outlier Discovery)

2. 定义：与其余数据显著不同的对象（如欺诈检测、极值分析）。
3. 方法分类：
 - 统计方法：假设数据服从特定分布（如正态），使用不一致性检验 (Inconsistency test)。缺点是需要知道分布。
 - 基于距离的方法： $DB(p, D)$ - 至少比例 p 的对象的距离大于 D 。无需分布假设。
 - 基于偏差的方法 (Deviation-based): 识别偏离主要特征的对象（如序列异常）。

第五部分：公式详解与例题预测

本部分针对“开卷考试”设计，请务必标记。

1. 重点公式：二元变量距离计算

考题预测：给定一张像PPT第18页那样的患者属性表（姓名、性别、症状等），计算不同人之间的距离。

2. Jaccard 系数（用于非对称二元变量，如症状）：

- 公式： $dist = \frac{b+c}{a+b+c}$
- a : 两人都有该症状 (1,1)
- b : 人A有(1), 人B无(0)
- c : 人A无(0), 人B有(1)

- d : 两人都无 (0,0) -> Jaccard 忽略此项。

3. 例题解析 (PPT原例) :

- Jack: (1, 0, 1, 0, 0, 0)
- Mary: (1, 0, 1, 0, 1, 0) (假设数据)
- 计算 Jack 和 Mary 的距离:
 - 找到不对称属性集合。
 - a (都为1的个数), b (1,0的个数), c (0,1的个数)。
 - 代入公式。

2. 重点公式: 闵可夫斯基距离

考题预测: 计算两个数值向量的欧几里得距离和曼哈顿距离。

- 数据: $X = (1, 2), Y = (3, 5)$
- 曼哈顿 ($q = 1$): $|1 - 3| + |2 - 5| = 2 + 3 = 5$
- 欧几里得 ($q = 2$): $\sqrt{(1 - 3)^2 + (2 - 5)^2} = \sqrt{4 + 9} = \sqrt{13}$

3. 重点概念: CF向量加法 (BIRCH算法)

考题预测: 给出两个簇的CF向量, 求合并后的CF向量。

- $CF_1 = (N_1, LS_1, SS_1)$
- $CF_2 = (N_2, LS_2, SS_2)$
- 合并结果:

$$CF_{new} = CF_1 + CF_2 = (N_1 + N_2, LS_1 + LS_2, SS_1 + SS_2)$$
- 原理: CF向量满足线性可加性。

4. 重点概念: PAM算法的总交换成本

考题预测: 解释如何判断是否替换中心点。

- 计算 $TC_{ih} = \sum_j C_{jih}$ 。
- C_{jih} 是所有非中心点 j 因中心点 i 被 h 替换而产生的代价变化。
- 如果 $TC_{ih} < 0$, 说明替换后总距离减小, 执行替换。

5. 重点概念：DBSCAN 密度

考题预测：给定点图和 $\epsilon, MinPts$ ，判断哪些是核心点，哪些是噪声。

- 判据：画一个半径 ϵ 的圈，如果圈内点数（含自身） $\geq MinPts$ ，则是核心点。
- 如果点在核心点的圈内，但自己圈内点少，则是边界点。
- 其他的为噪声。

第六部分：考试预测与回答策略

预测题型 1：算法对比

题目：对比 K-Means 和 K-Medoids (PAM) 的优缺点。

回答：

- **K-Means**：效率高 ($O(tkn)$)，但对噪声和异常值极其敏感（均值易被拉偏），需预设 k ，仅适用于凸形簇。
- **K-Medoids**：鲁棒性强（使用真实点作为中心，抗噪声），但计算代价高 ($O(k(n-k)^2)$)，适用于小规模数据。

预测题型 2：层次聚类策略

题目：解释 AGNES 和 DIANA 的区别。

回答：

- **AGNES** 是凝聚（自底向上）策略，开始时每个对象是一个簇，通过合并最相似的簇直到满足条件。
- **DIANA** 是分裂（自顶向下）策略，开始时所有对象在一个簇，通过分裂直到每个对象是一个簇。

预测题型 3：算法适用性

题目：如果数据包含大量噪声且形状不规则（如S形），应选择哪种算法？为什么？

回答：

- 应选择 **DBSCAN** 或 **CURE**。
- 理由：K-Means 假设簇是球形的且对噪声敏感。DBSCAN 基于密度，能天然发现任意形状的簇并过滤噪声。CURE 通过多个代表点和收缩因子，也能适应非球形簇。

预测题型 4：计算题

题目：计算混合属性的相异度。

回答：使用加权公式。对于分类型属性，匹配为0，不匹配为1；对于数值型，归一化后计算距离；对于二元型，看是否非对称。最后加权平均。

六：异常值分析 (Outlier Analysis)

第一部分：知识点全解与公式详解

1. 基础概念 (Introduction)

[Source: 13-25]

- **定义：**异常值 (Outlier) 是与其他数据对象偏差极大的数据对象，仿佛它是由不同的机制产生的。
- **例子：**异常的信用卡消费、体育界的迈克尔·乔丹（也就是极度优秀）、韦恩·格雷茨基。
- **异常值 vs. 噪声 (Noise)：**
 - **噪声：**测量变量中的随机误差或方差。在检测异常值之前，通常应消除噪声。
 - **异常值：**是有趣的数据，违反了生成正常数据的机制。
- **应用场景：**信用卡欺诈检测、电信欺诈检测、客户细分、医学分析。

2. 异常值的类型 (Types of Outliers)

[Source: 26-54]

2.1 全局异常值 (Global Outliers / Point Anomalies)

- **定义：**如果一个数据对象与整个数据集的其余部分有显著偏差，则为全局异常值。
- **例子：**计算机网络中的入侵检测。
- **核心问题：**找到合适的偏差测量方法。

2.2 上下文异常值 (Contextual / Conditional Outliers)

16. **定义：**一个对象在特定的上下文 (Context) 中显著偏差，但在其他情况下可能正常。
17. **属性分类：**
 - **上下文属性 (Contextual Attributes)：**定义上下文 (如：时间、地点)。
 - **行为属性 (Behavioral Attributes)：**对象的特征，用于评估是否异常 (如：温度)。
18. **例子：**气温 80°F (约26°C)。
 - 在“夏天” (上下文) 是正常的。

- 在“冬天”（上下文）是异常的。
19. **本质**：可以看作是局部异常值（其密度明显偏离其所在区域）。

2.3 集体异常值 (Collective Outliers)

6. **定义**：数据对象的子集作为一个整体与整个数据集有显著偏差，即使个别对象本身可能不是异常值。
7. **例子**：拒绝服务攻击（DoS），多台计算机不断发送数据包（单个包可能正常，但集体行为异常）。
8. **前提**：需要具备数据对象之间关系的背景知识（如距离、相似性、序列关系）。

3. 异常值检测方法分类

[Source: 68-114]

A. 基于监督模式分类

7. **监督方法 (Supervised)**:
 - **建模为分类问题**：训练集包含“正常”和“异常”标签。
 - **挑战**:
 - **类别不平衡 (Class Imbalance)**：异常值极少。解决方法：增强异常值类别，制造人工异常值。
 - **召回率 (Recall) 更重要**：即使误报（False Positive），也不能漏报（False Negative）。
8. **无监督方法 (Unsupervised)**:
 10. **假设**：正常对象会聚类，异常值远离聚类。
 11. **缺点**：难以检测集体异常值；高假阳性率；难以区分噪声和异常值。
9. **半监督方法 (Semi-supervised)**:
 - **场景**：标签数据很少（可能只有正常数据的标签）。
 - **方法**：用标记的正常数据训练模型，不符合模型的即为异常值。

B. 基于技术路线分类

6. **统计方法 (Statistical / Model-based)**
7. **基于邻近度的方法 (Proximity-based)**：基于距离或密度。
8. **基于聚类的方法 (Clustering-based)**
9. **分类方法 (Classification-based)**

4. 统计方法 (Statistical Methods) —— 公式重点

[Source: 115-249]

核心思想：假设正常数据遵循某种统计模型（随机模型），不遵循模型的数据即为异常值。

4.1 参数方法 (Parametric Methods)

假设数据服从已知的分布（如正态分布），通过数据估计参数（如均值 μ 和方差 σ^2 ）。

(1) 单变量正态分布检测

原理：利用最大似然估计 (MLE) 计算参数，然后检测数据点属于该分布的概率。

公式详解：

5. 最大似然估计公式：

$$\ln \mathcal{L}(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

6. 参数计算（你需要背这个）：

2. 均值估计: $\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

3. 方差估计: $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

7. 判别标准：

通常使用 3σ 原则。如果 $|x - \hat{\mu}| > 3\hat{\sigma}$ ，则认为是异常值（因为 $\mu \pm 3\sigma$ 包含了 99.7% 的数据）。

例题讲解 (PPT P17):

数据: {24.0, 28.9, 28.9, 29.0, 29.1, 29.1, 29.2, 29.2, 29.3, 29.4}, $n = 10$

5. 计算均值 $\hat{\mu} = 28.61$

6. 计算标准差 $\hat{\sigma} = \sqrt{2.29} = 1.51$

7. 检测值 24.0: $(24 - 28.61)/1.51 = -3.04$

8. 结论: $-3.04 < -3$ ，所以 24.0 是异常值。

(2) 格鲁布斯检验 (Grubbs' Test / Z-score)

原理：假设正态分布，使用 Z-score 进行检验。

公式详解：

$$z \geq \frac{N-1}{\sqrt{N}} \sqrt{\frac{t_{\alpha/(2N), N-2}^2}{N-2+t_{\alpha/(2N), N-2}^2}}$$

- N ：数据集对象数量。
- t ：t-分布值。
- α ：显著性水平（Significance level）。
- 理解：如果一个点的 Z-score 大于右边的复杂阈值，它就是异常值。

(3) 多变量异常值检测

- 方法1：马哈拉诺比斯距离 (Mahalanobis Distance)

$$MDist(o, \bar{o}) = \sqrt{(o - \bar{o})^T S^{-1} (o - \bar{o})}$$

5. $\bar{o}$ ：均值向量。

6. S ：协方差矩阵。

7. 解释：这是标准化的欧几里得距离，考虑了属性间的相关性。计算出距离后，可以使用 Grubb 检验。

- 方法2： χ^2 (卡方) 统计量

$$\chi^2 = \sum_{i=1}^n \frac{(o_i - E_i)^2}{E_i}$$

○ o_i ：观测值。

○ E_i ：期望值。

○ 如果 χ^2 很大，则是异常值。

(4) 混合参数分布 (Mixture Models)

场景：数据看起来像是多个分布混合而成的（例如两个聚类），用单一正态分布拟合效果差。

公式：

$$Pr(o|\Theta_1, \Theta_2) = f_{\Theta_1}(o) + f_{\Theta_2}(o)$$

- 方法：使用 **EM算法** (Expectation-Maximization) 从数据中学习参数。
- 判别：如果对象不属于任何一个混合成分（概率低），则为异常值。

4.2 非参数方法 (Non-parametric Methods)

不假设先验模型，从数据中构建模型。

- **直方图 (Histogram)**:
 - 构造直方图，如果对象落入的箱子 (Bin) 非常稀疏（频率极低），则是异常值。
 - **问题**：箱子大小 (Bin size) 很难选。太小导致正常点变异常（假阳性），太大导致异常点被淹没（假阴性）。
- **核密度估计 (Kernel Density Estimation)**:
 - 比直方图更平滑，估计概率密度函数。密度低的地方是异常值。

5. 基于邻近度的方法 (Proximity-based Methods)

[Source: 126-137, 258-303]

5.1 基于距离 (Distance-based)

定义：如果一个对象的邻域中没有足够的其他点，它就是异常值。

判别公式 (PPT P24):

$$\frac{||\{o' | dist(o, o') \leq r\}||}{||D||} \leq \pi$$

12. r ：距离阈值。

13. π ：分数阈值。

14. **解释**：在距离 O 为 r 的范围内，点的数量占比小于 π ，则 O 是异常值。

算法优化：

11. 嵌套循环 (Nested Loop): $O(N^2)$ ，效率低。
12. 基于网格 (Grid-based / Cell Pruning):

- 将空间划分为网格，单元格对角线长度为 $r/2$ 。
- 剪枝规则 (Pruning):
 - Level 1: 如果一个单元格内的点很多，那里面的点肯定不是异常值（不用查）。
 - Level 2: 如果一个单元格加上其直系邻居的点很少，那里面的点肯定是异常值（或者需要详细查）。
- 优点：不需要计算所有距离，线性时间复杂度（在低维情况下）。

5.2 基于密度 (Density-based) - LOF思想

定义：如果一个对象的密度比其邻居的密度低得多，则该对象为异常值（局部异常值）。

核心概念：

- k -距离 (k -distance): 点 o 到其第 k 个最近邻居的距离。
- k -距离邻域 ($N_k(o)$): 距离在 k -距离以内的所有点。
- 相对密度: 比较 o 的密度和 $N_k(o)$ 中邻居的密度。如果 o 的密度远小于邻居，说明 o 是孤立的。
- 解决的问题: 解决了全局密度不同导致的问题（见 PPT P26 的图，C1 稀疏，C2 密集，全局阈值无法同时检测 O1, O2 和 O3）。

6. 基于聚类的方法 (Clustering-based Methods)

[Source: 138-147, 311-351]

主要思想：

- 不属于任何聚类。
- 距离最近的聚类中心很远。
- 属于极小或稀疏的聚类。

算法：CBLOF (Cluster-Based Local Outlier Factor)

检测小簇中的异常值。

- 如果 p 属于大簇：

$$CBLOF = |C| \times sim(p, C)$$

(簇大小 $\times$ p 与簇的相似度)

- 如果 p 属于小簇：

$$CBLOF = |C| \times sim(p, C_{large})$$

(簇大小 $\times$ p 与最近的大簇的相似度)

- 解释：如果你在一个很小的簇里，且离最近的大部队很远，那你就是异常值。

优缺点：

- 优点：无需标签，速度快（聚类后只需比较距离）。
- 缺点：依赖聚类效果，计算成本高（聚类本身耗时）。

7. 基于分类的方法 (Classification-based Methods)

[Source: 360-403]

- 单类模型 (One-class Model):
 - 因为负例（异常值）很少，所以训练一个仅描述“正常类”的分类器（如 One-class SVM）。
 - 任何在决策边界之外的都是异常值。
- 半监督学习：
 - 利用已有的少量标签（正常或异常）结合聚类来提炼模型。

8. 挖掘上下文和集体异常值

[Source: 412-466]

8.1 挖掘上下文异常值

策略：

- 转换法：将上下文属性用于分组，在组内使用常规异常值检测（例如：按“季节”分组，在“冬季”组内找温度异常值）。
- 建模法：训练预测模型。
 - 输入：上下文属性。
 - 输出：预期的行为属性。

- 如果实际行为与预测值偏差大 $\rightarrow$ 异常。

8.2 挖掘集体异常值

策略：

- 结构单元化：将子序列、子图视为一个新的“数据对象”。
- 提取特征：对这些结构单元提取特征。
- 检测：对结构单元进行常规异常值检测。
- 例子：在社交网络中，发现频率极低的小子图，或出奇频繁的大型子图。

9. 高维数据中的异常值检测 (High-Dimensional Data)

[Source: 475-535]

挑战：

- 维数灾难：随着维数增加，数据变得稀疏，所有点之间的距离都趋于相等，距离度量失效。
- 子空间：异常值通常只在某些特定的子空间（部分维度）中表现出异常。

方法：

9.1 扩展常规方法 (HilOut 算法)

5. 基于距离，但使用距离的排名 (Rank) 而不是绝对距离。
6. 权重 $w(o) = \sum (到 k 个最近邻的距离)$ 。
7. 使用空间填充曲线 (Space-filling curve) 进行近似加速。

9.2 基于网格的子空间方法

2. 原理：在子空间中找稀疏区域。

3. 稀疏系数公式 $S(C)$ ：

$$S(C) = \frac{n(C) - f^k n}{\sqrt{f^k(1 - f^k)n}}$$

- $n(C)$ ：立方体 C 中的对象数。
- f ：每个维度的范围划分比例。

- k : 维度。
- 结论: 如果 $S(C)$ 是较大的负值, 说明该区域比预期的要稀疏, 可能是异常值。

9.3 基于角度的方法 (ABOF - Angle-Based Outlier Factor)

原理: 在高维空间中, 角度比距离更稳定。

- 正常点: 位于簇中心, 与周围点的角度变化大 (方差大) 。
- 异常点: 位于边缘, 看所有其他点的角度都很小, 角度变化小 (方差小) 。
- ABOF 公式:

$$ABOF(o) = VAR_{x,y \in D} \left(\frac{\langle \overline{ox}, \overline{oy} \rangle}{dist(o, x)^2 dist(o, y)^2} \right)$$

- 判别: ABOF 值越小, 越可能是异常值 (因为方差小) 。

第二部分：重点难点总结 (Quick Review)

维度	关键点	易错点
定义	异常值 vs 噪声	噪声是误差要删掉, 异常值是有意义的要保留。
类型	全局、上下文、集体	上下文需要区分Context和Behavior属性; 集体是看整体结构。
参数统计	3σ 原则, MLE, Mahalanobis	记得 3σ 覆盖 99.7% 数据。Mahalanobis 距离考虑了属性相关性。
邻近度	距离 vs 密度	距离法基于半径内点的个数; 密度法 (LOF) 解决密度不均问题。
高维	ABOF (基于角度)	高维下距离失效, 角度方差

		小的是异常值。
评估	召回率 vs 准确率	异常检测更看重召回率（不漏报）。

第三部分：考题预测与答题技巧

说明：由于是开卷考试，题目通常不会直接问定义，而是考察理解、计算或场景分析。

题型 1：概念辨析与简答

Q1: 异常值检测和噪声去除有什么区别？

4. 答：噪声是数据收集过程中的随机误差（如传感器故障），通常是被动的干扰，应当被移除以提高数据质量。异常值是真实存在的数据点，虽然偏离正常模式，但可能包含重要信息（如欺诈、新发现），是数据挖掘的目标之一。

Q2: 为什么在高维数据中，传统的基于距离的异常值检测方法会失效？

2. 答：这被称为“维数灾难”。随着维数增加，数据在空间中变得极其稀疏，任何两个数据点之间的距离差异变得微不足道（距离集中效应），导致无法区分哪个点离邻居更远，因此基于距离的度量不再有效。

Q3: 解释什么是“屏蔽效应”(Masking) 和“淹没效应”(Swamping)? （PPT P6 提到噪声可能隐藏异常值）

2. 答：
- Masking: 异常值过多或聚集，导致统计模型（如均值、方差）被扭曲，使得异常值看起来像正常值。
 - Swamping: 正常值因为模型偏差被错误地标记为异常值。

题型 2：计算题 (重点复习)

Q4: 给定一组一维数据，请使用最大似然估计法判断 x 是否为异常值。

● 策略：

1. 列出表格计算 $\sum x_i$ 和 $\sum (x_i - \bar{x})^2$ 。
2. 套用公式 $\hat{\mu} = \frac{1}{n} \sum x_i$ 计算均值。
3. 套用公式 $\hat{\sigma} = \sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2}$ 计算标准差。

4. 计算 Z-score: $z = \frac{x - \hat{\mu}}{\hat{\sigma}}$ 。
5. 判断: 如果 $|z| > 3$, 则是异常值。

Q5: 计算 Mahalanobis 距离的意义是什么?

- 答: 它消除了变量之间的量纲差异, 并考虑了变量之间的相关性 (通过协方差矩阵 S 的逆矩阵)。如果是单位矩阵 (不相关), 它就退化为欧几里得距离。

题型 3: 场景设计题

Q6: 你正在为一家电商公司设计反欺诈系统。你会使用什么类型的异常值检测? 请说明理由。

- 答: 建议结合上下文异常值和集体异常值检测。
 - 上下文: 用户的消费金额需要结合“时间” (双11 vs 平时) 和“历史行为” (该用户平时消费水平) 作为上下文。
 - 集体: 欺诈往往不是单次行为, 而是短时间内的一系列操作 (如频繁退货、短时间多地登录), 这属于集体异常模式。
 - 方法: 可以使用半监督学习 (利用已有的欺诈标签) 或基于密度的方法 (检测孤立的异常行为模式)。

Q7: 如何使用基于网格的方法加速基于距离的异常值检测?

- 答: 将空间划分为对角线为 $r/2$ 的网格。
 - Level 1 剪枝:** 如果某个网格内的点数已经超过阈值 (如 $> k$), 则该网格内所有点都不是异常值 (因为它们彼此距离都小于 r)。
 - Level 2 剪枝:** 如果一个网格及其所有邻接网格的总点数加起来都不足阈值, 则该网格内的所有点都是异常值。
只有无法被这两层规则剪枝的点才需要进行详细的距离计算, 从而大幅减少计算量。

七: 频繁模式、关联规则与相关性

第一部分: 基本概念 (Basic Concepts)

1. 什么是频繁模式 (Frequent Pattern)?

10. 定义: 在数据集中频繁出现的模式 (如项集、子序列、子结构)。

- 11. 起源：由 Agrawal 等人在 1993 年提出，用于购物篮分析（啤酒与尿布）。
- 12. 应用：购物篮分析、交叉营销、网络日志分析、DNA 序列分析。

2. 核心术语定义(关键!)

- 项集 (Itemset): 一个或多个项目的集合。例如: $X = \{x_1, \dots, x_k\}$ 是一个 k -项集。
- 支持度计数 (Absolute Support / Support Count): 项集 X 在数据库中出现的频率或次数。
- 相对支持度 (Relative Support, s): 包含 X 的交易占总交易的比例 (概率)。
 - 公式: $s(X) = \frac{\text{包含X的交易数}}{\text{总交易数}}$
- 频繁项集 (Frequent Itemset): 如果项集 X 的支持度不低于预设的最小支持度阈值 (min_sup), 则称 X 为频繁项集。

3. 关联规则 (Association Rules)

- 形式: $X \Rightarrow Y$ (其中 X, Y 为项集, 且 $X \cap Y = \emptyset$)。
- 两个核心指标:
 - 支持度 (Support, s): 交易同时包含 X 和 Y 的概率。
 - $s(X \Rightarrow Y) = P(X \cup Y)$
 - 置信度 (Confidence, c): 包含 X 的交易中也包含 Y 的条件概率。
 - $c(X \Rightarrow Y) = P(Y|X) = \frac{\text{support}(X \cup Y)}{\text{support}(X)}$
- 强关联规则: 同时满足最小支持度 (min_sup) 和 最小置信度 (min_conf) 的规则。

4. 压缩模式: 闭项集与最大项集 (Closed & Maximal Patterns)

- 9. 背景: 长模式会产生指数级数量的子模式, 导致结果过多。
- 10. 闭项集 (Closed Pattern):

- 条件1: X 是频繁的。
- 条件2: 不存在 X 的超集 Y ($Y \supset X$) 拥有与 X 相同的支持度。
- 总结: 它是无损压缩 (Lossless Compression), 不丢失支持度信息。

11. 最大项集 (Maximal Pattern):

- 条件1: X 是频繁的。
- 条件2: 不存在 X 的超集 Y ($Y \supset X$) 是频繁的。
- 总结: 它是有损压缩, 只知道它是频繁的, 但不知道具体支持度。

第二部分: Apriori 算法 (Candidate Generation & Test)

1. 核心原理: 先验性质 (Apriori Property / Downward Closure)

- 12. 定律: 如果一个项集是频繁的, 那么它的所有非空子集也必须是频繁的。
- 13. 逆否命题 (用于剪枝): 如果一个项集是非频繁的, 那么它的所有超集也一定是非频繁的。

- 12. 例子: 如果 $\{Beer\}$ 是非频繁的, 那么 $\{Beer, Diapers\}$ 也不可能是频繁的, 无需测试。

2. 算法流程

- 6. 连接 (Join): L_k 自连接生成 C_{k+1} (候选集)。
- 7. 剪枝 (Prune): 利用先验性质, 删除包含非频繁子集的候选项。
- 8. 扫描: 扫描数据库计算候选项支持度, 筛选出 L_{k+1} 。
- 9. 终止: 直到无法生成新的频繁项集。

3. 候选生成与剪枝的具体操作 (以 $L_3 \rightarrow C_4$ 为例)

- 10. 假设 $L_3 = \{abc, abd, acd, ace, bcd\}$ 。
- 11. 自连接: 寻找前 $k-1$ 项相同的对。
 - abc 和 $abd \rightarrow abcd$ 。
 - acd 和 $ace \rightarrow acde$ 。
- 12. 剪枝检查:
 - 4. 对于候选 $abcd$, 检查其子集 abc, abd, acd, bcd 是否都在 L_3 中。
 - 5. 如果 $acde$ 的子集 cde 不在 L_3 中, 则删除 $acde$ 。

4. Apriori 的性能瓶颈

9. 需多次扫描数据库 (k 次)。
10. 生成大量候选项。
11. 计数工作量大。

5. Apriori 的改进算法

- **Partition (分区法)**: 只需扫描数据库 2 次。
 1. 原理: 全局频繁的项集在至少一个分区中必须是局部频繁的。
- **DHP (Direct Hashing and Pruning)**: 利用哈希桶计数减少候选项。如果桶的计数小于阈值, 则桶内所有项集都不可能是频繁的。
- **Sampling (采样法)**: 牺牲精度换速度, 利用小样本估计, 最后全库验证边界。

第三部分: FP-Growth 算法 (Pattern Growth)

1. 核心思想

- 深度优先搜索 (Depth-first search)。
- 不生成候选项 (No Candidate Generation)。
- 利用 **FP-Tree (频繁模式树)** 压缩数据库。

2. 算法步骤

10. 构建 **FP-Tree**:
 - 第一次扫描: 统计 1-项集频率, 按频率**降序**排列 (F-list)。
 - 第二次扫描: 按 F-list 顺序将每条交易插入树中, 共享相同前缀的路径。
11. 挖掘 **FP-Tree**:
 - 从 F-list 的底部项 (频率最低) 开始。
 - 构建该项的 **条件模式基 (Conditional Pattern Base)**。
 - 根据条件模式基构建 **条件 FP-Tree (Conditional FP-Tree)**。
 - 递归挖掘。

3. 关键概念详解

- **Header Table (头表)**: 存储项的链表头, 用于快速访问树中节点。
- **Conditional Pattern Base (条件模式基)**:
 - 对于节点 x , 它是 FP-Tree 中所有通向 x 的前缀路径的集合 (路径计数等于 x 的计数)。
 - 例子: 如果路径是 $f : 4 \rightarrow c : 3 \rightarrow a : 3 \rightarrow m : 2$, 对于 m , 其前

缀路径是 $\{f, c, a\} : 2$ 。

- **Conditional FP-Tree**: 基于条件模式基, 重新统计频率, 剔除不满足 min_sup 的项, 构建的小树。

4. 优缺点

15. 优点:

- 比 Apriori 快 (通常快一个数量级)。
- 不需要生成候选项。
- 只需扫描数据库2次。
- 分而治之 (Divide and Conquer)。

16. 扩展性问题: 如果树太大无法放入内存, 需使用 **Projected DB (投影数据库)** 方法 (并行投影或分区投影)。

第四部分：垂直数据格式 (ECLAT)

6. 思想: 将数据从横向 (TID -> Itemset) 转为纵向 (Item -> TID_List)。

7. **TID-List**: 记录包含该项集的所有交易ID。

8. 运算: 频繁项集挖掘变成了 TID-List 的 **交集 (Intersection)** 运算。

○
$$t(XY) = t(X) \cap t(Y)$$

○ 支持度 = $|t(XY)|$ 。

9. 优点: 无需计数, 直接求交集长度。

第五部分：模式评估 (Pattern Evaluation)

单纯使用支持度和置信度可能会产生误导 (例如: 虽然规则置信度高, 但实际上两者是负相关的)。

1. 提升度 (Lift) —— 必考公式

衡量 A 的出现对 B 出现概率的提升程度。

$$Lift(A, B) = \frac{P(A \cup B)}{P(A)P(B)}$$

或者写成：

$$Lift(A \rightarrow B) = \frac{c(A \rightarrow B)}{s(B)}$$

- **Lift > 1**: 正相关 (Positive correlation)。
- **Lift = 1**: 独立 (Independent)。
- **Lift < 1**: 负相关 (Negative correlation)。

2. 卡方检验 (χ^2 , Chi-Square)

$$\chi^2 = \sum \frac{(\text{Observed} - \text{Expected})^2}{\text{Expected}}$$

- 用于测试变量独立性。
- 值越大，相关性越强（无论正负）。

3. 其他度量 (Slide 55 表格摘要)

- **Null-Invariant Measures (零无关度量)**: 不受 Null-Transactions（既不包含A也不包含B的交易）数量影响的指标。
 - 包括: **Cosine, Jaccard, All-confidence, Coherence**。
 - *Lift* 和 χ^2 不是零无关的，它们受数据总数影响很大。

第六部分：公式详解与例题讲解 (Exam Prep)

公式 1：关联规则生成 (支持度与置信度)

题目预测：给定一个小型交易数据集，求 $\{A, B\} \rightarrow \{C\}$ 的置信度。

数据：

T1: A, B, C

T2: A, B

T3: A, B, C, D

T4: B, C

计算:

- 找到 $X = \{A, B\}$ 的支持次数: T1, T2, T3 (共3次)。
- 找到 $X \cup Y = \{A, B, C\}$ 的支持次数: T1, T3 (共2次)。
- $Confidence = 2/3 = 66.7\%$ 。

公式 2: Lift (提升度) 计算

题目预测: 打篮球与吃麦片的关系。

- 总人数 5000。
- 打篮球 (A): 3000人。
- 吃麦片 (B): 3750人。
- 既打篮球又吃麦片 ($A \cap B$): 2000人。

计算:

$$P(A) = 3000/5000 = 0.6$$

$$P(B) = 3750/5000 = 0.75$$

$$P(A \cup B) = 2000/5000 = 0.4$$

$$Lift = \frac{0.4}{0.6 \times 0.75} = \frac{0.4}{0.45} = 0.89$$

结论: $Lift < 1$, 说明打篮球和吃麦片是负相关的。

公式 3: 先验剪枝 (Apriori Pruning)

题目预测: 给定 $L_3 = \{abc, abd, acd, ace, bcd\}$, 生成的候选 C_4 是什么?

解答:

5. 连接: abc 和 abd 合并 $\rightarrow abcd$ 。

6. 剪枝：检查 $abcd$ 的子集：
- $abc \in L_3$ (OK)
 - $abd \in L_3$ (OK)
 - $acd \in L_3$ (OK)
 - $bcd \in L_3$ (OK)
 - 所有子集都在 L_3 中，保留 $abcd$ 。
7. 连接： acd 和 ace 合并 $\rightarrow acde$ 。
8. 剪枝：检查 $acde$ 的子集：
- cde 是否在 L_3 中？不在！
 - 删除 $acde$ 。
- 最终答案： $C_4 = \{abcd\}$ 。

第七部分：可能出现的简答/分析题预测

Q1: 比较 Apriori 和 FP-Growth 的优缺点。

- **Apriori:**
 - 优点：简单，易于实现，内存占用少（如果是基于磁盘）。
 - 缺点：需多次扫描数据库，生成庞大的候选项集，在长模式下性能差。
- **FP-Growth:**
 - 优点：扫描次数少（2次），无候选项生成，利用树结构压缩数据，速度快。
 - 缺点：构建FP-Tree需要大量内存，树是非平衡的，实现相对复杂。

Q2: 什么是 Closed Pattern 和 Maximal Pattern? 它们有什么区别?

8. 回答要点：
- Closed Pattern（闭模式）：如果一个频繁项集没有与其支持度相同的超集。它是无损的。
 - Maximal Pattern（最大模式）：如果一个频繁项集没有任何频繁的超集。它是有损的。

- 关系：Maximal $\subseteq$ Closed $\subseteq$ Frequent。闭模式包含了所有最大模式。

Q3: 为什么 Lift 比 Confidence 更能反映相关性？

4. 回答要点：Confidence 忽略了后件（Consequent）本身的支持度。如果后件本身发生概率就很高（例如“买面包”），那么 Confidence 可能会误导我们认为前件导致了后件。Lift 考虑了后件的基准概率，通过比值判断是正相关、负相关还是独立。

Q4: 在 FP-Growth 中，什么是条件模式基（Conditional Pattern Base）？

11. 回答要点：它是以某个特定项（后缀）为结尾的所有前缀路径的集合。这些路径用于构建该条件的 FP-Tree，从而递归地挖掘包含该项的频繁模式。

Q5: 描述 ECLAT 算法的基本原理。

5. 回答要点：使用垂直数据格式（Vertical Data Format）。将数据表示为 Item $\rightarrow$ TID_Set。通过计算 TID_Set 的交集（Intersection）来确定项集的支持度，避免了扫描数据库和复杂的计数过程。

八：高级频繁模式挖掘 (Advanced Frequent Pattern Mining)

第一部分：知识点全景总结 (Knowledge Map)

1. 多层次与多维空间中的模式挖掘 (Multilevel & Multidimensional)

1.1 多层次关联规则 (Multilevel Association Rules)

13. 概念：项目通常具有层次结构（例如：牛奶 $\rightarrow$ 2%牛奶 $\rightarrow$ 脱脂牛奶）。
14. 支持度设置策略：
 1. 统一支持度 (Uniform Support)：所有层级使用相同的最小支持度阈值。
 - 缺点：如果阈值太高，可能会遗漏底层（低频）的具体项目；如果太低，高层（高频）项目会产生组合爆炸。
 2. 递减支持度 (Reduced Support)：层级越低，所需的最小支持度越低。
 - 优点：灵活，符合“具体商品销量通常低于类别销量”的规律。
15. 冗余过滤 (Redundancy Filtering)：
 - 由于“祖先”关系的存在，某些规则是冗余的。
 - 判定标准：如果规则的支持度/置信度接近于基于其“祖先”规则的预期值，则该规则是冗余的。
 - 例子：如果“牛奶 $\rightarrow$ 面包”是强规则，那么“2%牛奶 $\rightarrow$ 小麦面包”即便满足阈值，如果其统计特性与“牛奶 $\rightarrow$ 面包”无显著差异，则可能被视为冗余。

1.2 多维关联规则 (Multidimensional Association Rules)

7. 规则类型:

- **跨维度 (Inter-dimension)**: 不包含重复谓词。例如: $\text{Age}(X, "19-25") \wedge \text{Occupation}(X, "Student") \rightarrow \text{Buys}(X, "Coke")$ 。
- **混合维度 (Hybrid-dimension)**: 包含重复谓词。例如: $\text{Age}(X, "19-25") \wedge \text{Buys}(X, "Popcorn") \rightarrow \text{Buys}(X, "Coke")$ 。

8. 属性处理:

- **分类属性**: 有限个值, 无序 $\rightarrow$ 使用数据立方体 (Data Cube) 方法。
- **定量属性** (数值型, 如年龄、薪水):
 - **静态离散化 (Static Discretization)**: 基于预定义的概念层次 (如: 0-10岁, 11-20岁)。需配合Data Cube。
 - **动态离散化 (Dynamic Discretization)**: 基于数据分布 (分箱等)。
 - **聚类 (Clustering)**: 基于距离的关联。
 - **偏差分析 (Deviation Analysis)**: 统计学方法 (如Z-test), 发现异常值。例如: $\text{Gender}=\text{Female} \Rightarrow \text{Wage: mean}=\$7/\text{hr}$ (总体平均 \$9), 揭示异常行为。

2. 稀有模式与负相关模式 (Rare and Negative Patterns)

2.1 稀有模式 (Rare Patterns)

2. 定义: 支持度很低但很有趣的模式 (例如: 购买劳力士手表)。
3. 挖掘方法: 针对特定有价值的项目设置较低的支持度阈值。

2.2 负相关模式 (Negative Patterns)

14. 概念: 项目集X和Y经常独立出现, 但很少同时出现 ($X \implies \neg Y$)。

15. 定义方法及其问题 (重点):

13. 定义1 (基于支持度): $\text{sup}(X \cup Y) < \text{sup}(X) \times \text{sup}(Y)$ 。

- **缺陷**: 非空不变性 (Not Null-Invariant)。即添加大量不包含X也不包含Y的“空交易”会改变结果, 导致误判。

14. 定义2 (基于负项集): 引入负项 $\bar{A}$ 。

15. 定义3 (基于Kulczynski度量 - 推荐):

- 若 $(P(X|Y) + P(Y|X))/2 < \epsilon$ (其中 ϵ 是负模式阈值), 则为负相关。
- **优点**: 解决了空不变性问题。

3. 基于约束的频繁模式挖掘 (Constraint-Based Mining) [核心考点]

3.1 约束的类型

8. 知识型约束: 关于分类、关联等。

9. 数据型约束：类似SQL查询（如 $\text{sum}(\text{price}) < 100$ ）。
10. 维度/层级约束：关于特定区域、品牌。
11. 兴趣度约束：强规则（ $\text{min_support}, \text{min_confidence}$ ）。

3.2 约束的性质 (Properties of Constraints) [必考]

用于剪枝 (Pruning) 以提高效率。

9. 反单调性 (Anti-monotonicity):

- 定义：如果项集 S 违反约束 C ，则 S 的所有超集也都违反 C 。
- 作用：如果 S 不满足，剪掉所有包含 S 的分支。
- 例子： $\text{sum}(\text{price}) < v$ (价格越加越大，一旦超过 v ，加更多肯定超过)， $\text{support}(S) > \text{min_sup}$ 。

10. 单调性 (Monotonicity):

- 定义：如果项集 S 满足约束 C ，则 S 的所有超集也都满足 C 。
- 作用：如果 S 满足，不需要再检查其超集（必定满足，但需挖掘其支持度）。
- 例子： $\text{sum}(\text{price}) > v$ ， $\text{count}(S) > v$ 。

11. 简洁性 (Succinctness):

2. 定义：可以在不扫描数据库的情况下，仅通过选择特定项目来生成满足约束的项集（Explicitly precise）。
3. 例子： $\text{min}(\text{price}) < v$ （直接选所有价格小于 v 的项即可）， $\text{start_with}(S, \text{"Microsoft"})$ 。
4. 注意： $\text{sum}(\text{price}) < v$ 不是简洁的，因为必须组合后才知道总和。

12. 可转换约束 (Convertible Constraints):

8. 定义：某些约束本身既不是单调也不是反单调，但在对项目进行特定排序后，表现出单调或反单调性。
9. 关键：排序 (Ordering)。
10. 例子： $\text{avg}(\text{price}) < v$ 。
 - 如果按价格降序排列项目：是可转换反单调的。如果前缀的平均值已经 $< v$ ，添加更小的数，平均值会更小（这个例子反了，见下文详细解释）。
 - 修正解释：对于 $\text{avg}(S) > v$ (平均值大于 v)。如果按价格降序排列。如果当前前缀平均值 $< v$ ，后面只有更小的数，平均值只会更低，永远无法 $> v$ 。所以可以剪枝。

3.3 剪枝策略

- 模式空间剪枝 (Pattern Space Pruning)：利用反单调性，不生成无效候选项。
- 数据空间剪枝 (Data Space Pruning)：利用数据反单调性。如果一个交易 t 不满足约束，则可以从挖掘中剔除该交易。

4. 挖掘庞大模式 (Colossal Patterns)

- **痛点**：对于非常长的模式（如长度50+），传统的Apriori或FP-Growth会因为“向下封闭属性”导致中等规模子模式呈指数级爆炸（ 2^{50} 个子模式）。
- **核心模式 (Core Patterns)**：庞大模式 α 的子模式 α' ，如果它们的支持度集合非常相似，则 α' 是 α 的核心模式。
- **Pattern-Fusion 算法**：
 - **策略**：跳出中等模式的泥以此，直接通过**融合 (Fusion) **小模式来生成大模式。
 - **特点**：有界宽度的树遍历、随机跳跃、能够识别“捷径”。
 - **距离度量**：使用样本空间重叠度来衡量模式间的距离。

5. 压缩与近似模式 (Compressed & Approximate)

- **δ -Clustering**：
 - 为了减少冗余，将距离在 δ 内的模式聚类。
 - 使用代表性模式 (Representative Pattern) 来代表一簇模式。
- **Redundancy-Aware Top-k**：
 - 不仅仅找支持度最高的k个（可能非常相似），而是找显著性高且冗余度低的k个模式。
 - 指标：**MMS (Maximal Marginal Significance)**。

6. 模式探索与语义注释 (Pattern Exploration)

10. **语义注释**：给模式加上上下文信息，解释“为什么”这个模式频繁。
11. **类比**：字典定义（单词=模式，定义=语义上下文）。
12. **方法**：提取上下文指示器 (Context Indicators) 和代表性交易。

第二部分：公式与算法深度解析 (Formulas & Explanations)

1. 负相关判定 (Negative Correlation)

公式A：支持度定义

$$\text{sup}(X \cup Y) < \text{sup}(X) \times \text{sup}(Y)$$

7. **含义**：实际同时出现的频率 < 假如两者独立时理论上同时出现的频率。

- 8. 考点：如果是从空交易极多的数据集中计算，这个公式不可靠（Null-invariance问题）。

公式B: Kulzynski 度量 (推荐)

$$\frac{P(X|Y) + P(Y|X)}{2} < \epsilon$$

- 含义：X出现时Y出现的概率，加上Y出现时X出现的概率，取平均。如果很小，说明两者互相排斥。

- 计算：

- $P(X|Y) = \frac{\text{count}(X \cup Y)}{\text{count}(Y)}$

- $P(Y|X) = \frac{\text{count}(X \cup Y)}{\text{count}(X)}$

2. 模式距离 (Pattern Distance) - 用于聚类 and 庞大模式

$$D(P_1, P_2) = 1 - \frac{|T(P_1) \cap T(P_2)|}{|T(P_1) \cup T(P_2)|}$$

- 解释： $T(P)$ 是包含模式 P 的交易ID集合 (Transaction Set) 。

- 含义：这是 Jaccard 距离的补数。

- 如果 P_1 和 P_2 总是同时出现在相同的交易里，交集=并集，分数为1，距离=0（完全相同）。
- 如果从不同时出现，交集=0，距离=1。

3. 可转换约束的排序判定 (Convertible Constraints)

这是最容易混淆的部分，请仔细阅读：

假设约束是 $avg(S) \geq 25$ (平均价格大于等于25)。

- 情况1：按价格降序排序 (Descending) $\langle a, f, g, d, b... \rangle$

- 假设当前项集 $S = \{a, f\}$ 。接下来的元素都比 f 小。

- 如果 $avg(\{a, f\}) < 25$ ，那么再添加更小的元素，平均值只会更小，永远无法 ≥ 25 。

- **结论**：在降序排列下，该约束是**反单调 (Anti-monotonic)** 的。（前缀不行，后缀更不行，剪枝！）
- **情况2：按价格升序排序 (Ascending) <b, d, g, f, a...>**
 - 假设当前项集 $S = \{b, d\}$ 。接下来的元素都比 d 大。
 - 如果 $avg(\{b, d\}) \geq 25$ ，那么再添加更大的元素，平均值通常会变大（或者保持高位）。
 - 这通常被视为**可转换单调 (Convertible Monotonic)** 的一种形式（需具体分析属性，PPT主要强调降序对应反单调）。

PPT中总结表 (Slide 37):

- $avg(S) \geq v$: 降序 -> 反单调；升序 -> 单调。
- $avg(S) \leq v$: 降序 -> 单调；升序 -> 反单调。
- $sum(S) \leq v$ (项可为负): 升序 -> 单调。

第三部分：可能出的考题预测与回答 (Exam Predictions)

题型一：约束性质判断 (Constraint Properties)

题目：给定以下约束，判断它们是单调的、反单调的、简洁的，还是可转换的？

- $sum(S.price) \leq 100$ (所有价格为正数)
- $min(S.price) \leq 50$
- $avg(S.price) \geq 30$
- $count(S) \geq 5$

参考答案：

- **反单调 (Anti-monotonic)**。
 - *理由*：如果当前总和已经 > 100 ，再加正数肯定 > 100 。子集违反，超集必违反。
- **简洁 (Succinct) 且 单调 (Monotonic)**。
 - *理由*：简洁性是因为我们可以直接从数据库选出所有 $price \leq 50$ 的项。单调性是因为如果集合里有一个数 ≤ 50 ，整个集合的最小值肯定 ≤ 50 。
- **可转换 (Convertible)**。
 - *理由*：平均值本身不是单调或反单调。但如果按价格**降序**排列，它是可转换反单调的；按**升序**排列，它是可转换单调的。
- **单调 (Monotonic)**。
 - *理由*：如果一个集合元素个数 ≥ 5 ，添加更多元素后个数肯定 ≥ 5 。

题型二：负相关模式计算

题目：

共有200笔交易。

A出现100次，B出现100次。A和B同时出现只有1次。

5. 使用基于支持度的定义，判断是否负相关（设阈值为支持度乘积）。

6. 使用Kulczynski度量计算并分析结果 ($\epsilon = 0.02$)。

参考答案：

12. $s(A) = 0.5, s(B) = 0.5$ 。

$$s(A \cup B) = 1/200 = 0.005$$

$$s(A) \times s(B) = 0.25$$

因为 $0.005 < 0.25$ ，所以是负相关。

13. $P(A|B) = 1/100 = 0.01$ 。

$$P(B|A) = 1/100 = 0.01$$

$$Kulc = (0.01 + 0.01)/2 = 0.01$$

因为 $0.01 < 0.02$ ，所以是负相关。

注意：如果交易总数变成 10^5 ，支持度法会失效（不等式方向可能改变），但Kulc方法结果不变，体现了Null-invariance。

题型三：庞大模式挖掘原理

题目：为什么传统的 Apriori 或 FP-Growth 算法无法有效挖掘庞大模式（Colossal Patterns）？Pattern-Fusion 算法是如何解决这个问题的？

参考答案：

6. 困难原因：受“向下封闭（Downward Closure）”属性的影响。如果存在一个长度为 50 的

频繁模式，那么它的所有 2^{50} 个子模式也都是频繁的。传统算法通常是逐层（Apriori）或逐个（FP-Growth）生成模式，这会导致在生成最终的庞大模式之前，被中等规模（如长度 20 左右）的模式数量爆炸卡死。

7. 解决方案 (Pattern-Fusion)：

- **跳跃策略**：不进行逐层搜索，而是通过融合（Fusion）小的核心模式（Core Patterns）直接生成大模式。
- **核心模式**：利用核心模式与其后代在支持度集上的高重叠性（距离近）。
- **有界宽度**：在每一步迭代中只保留固定数量（K）的候选池，避免搜索空间爆炸。

题型四：多层关联规则的支持度

题目：什么是“递减支持度（Reduced Support）”策略？为什么要使用它？

参考答案：

3. **定义**：在多层关联规则挖掘中，对层级越低（越具体）的项目设置越低的最小支持度阈值（如：Items级 5%，Brands级 3%，SKU级 1%）。
 4. **原因**：高层级的项目（如“牛奶”）通常比低层级的项目（如“2%雀巢牛奶”）出现频率高得多。如果使用统一的高阈值，会遗漏具体的稀有项；如果使用统一的低阈值，高层级项目会产生海量的组合。递减策略平衡了这一矛盾。
-